MBA em **IA** e **Dados** para Negócios

Traduzindo problemas de negócio em hipóteses analíticas

Apresentação do Módulo

inteli MBA

Boa noite!

FACILITADOR

Fábio Cássio Souza

Jornada de Negócios

Enterprise Architecture
Dados → Decisão dentro das organizações

TUTOR DE NEGÓCIOS

Natália Kloekner

Jornada de Negócios

Acompanhamento dos grupos
Tutorias semanais

Objetivos desta aula

1 Formular hipóteses testáveis a partir de um problema de negócio ambíguo.

2 Ligar cada hipótese a uma variável existente e medir se ela prevê o cancelamento.

3 Reconhecer três armadilhas: vazamento de dados, causalidade e uso ético de variáveis sensíveis.

Antes de olhar os dados

Qual variável você apostaria para prever cancelamento?

A. Tempo de casa

Anote seu palpite antes da revelação

B. Frequência de uso

Anote seu palpite antes da revelação

C. Tipo de contrato

Anote seu palpite antes da revelação

D. Idade

Anote seu palpite antes da revelação

Anote seu palpite. Vamos revelar no slide 8.

Uma hipótese testável tem três partes

1 Afirmação causal

"X faz Y acontecer."

Diz o que causa o quê, e em que direção.

2 Métrica

"Medido por..."

Qual variável ou taxa vai mostrar isso.

3 Critério de refutação

"Cai se..."

O resultado que derruba a hipótese, definido antes de olhar os dados.

Sem a terceira parte, a hipótese se ajusta a qualquer resultado. Isso é opinião com cara de análise.

Exemplo: de opinião a hipótese

Opinião (HIPPO)

"O preço está alto demais."

Sem métrica, sem critério de refutação.

Hipótese testável

"Assinantes do plano mensal cancelam mais nos primeiros 30 dias do que os do plano anual."

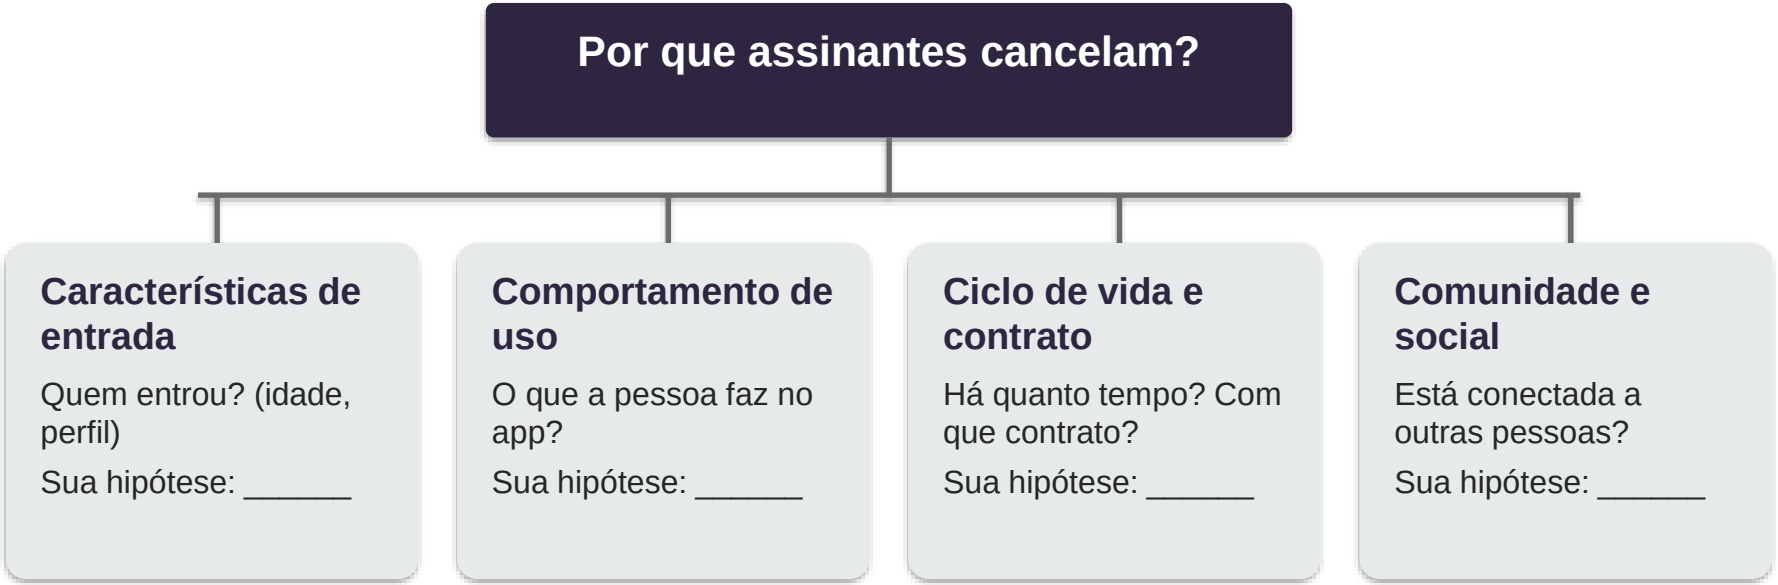
Métrica: churn até 1 mês de casa, por tipo de contrato.

Cai se a diferença não aparecer.

No arquivo: mensal 76% · anual 11% de churn no início (até 1 mês de casa).

Mas: a base não tem preço. A hipótese do preço não pode ser testada aqui. Isso também é informação.

Árvore de hipóteses: quatro galhos



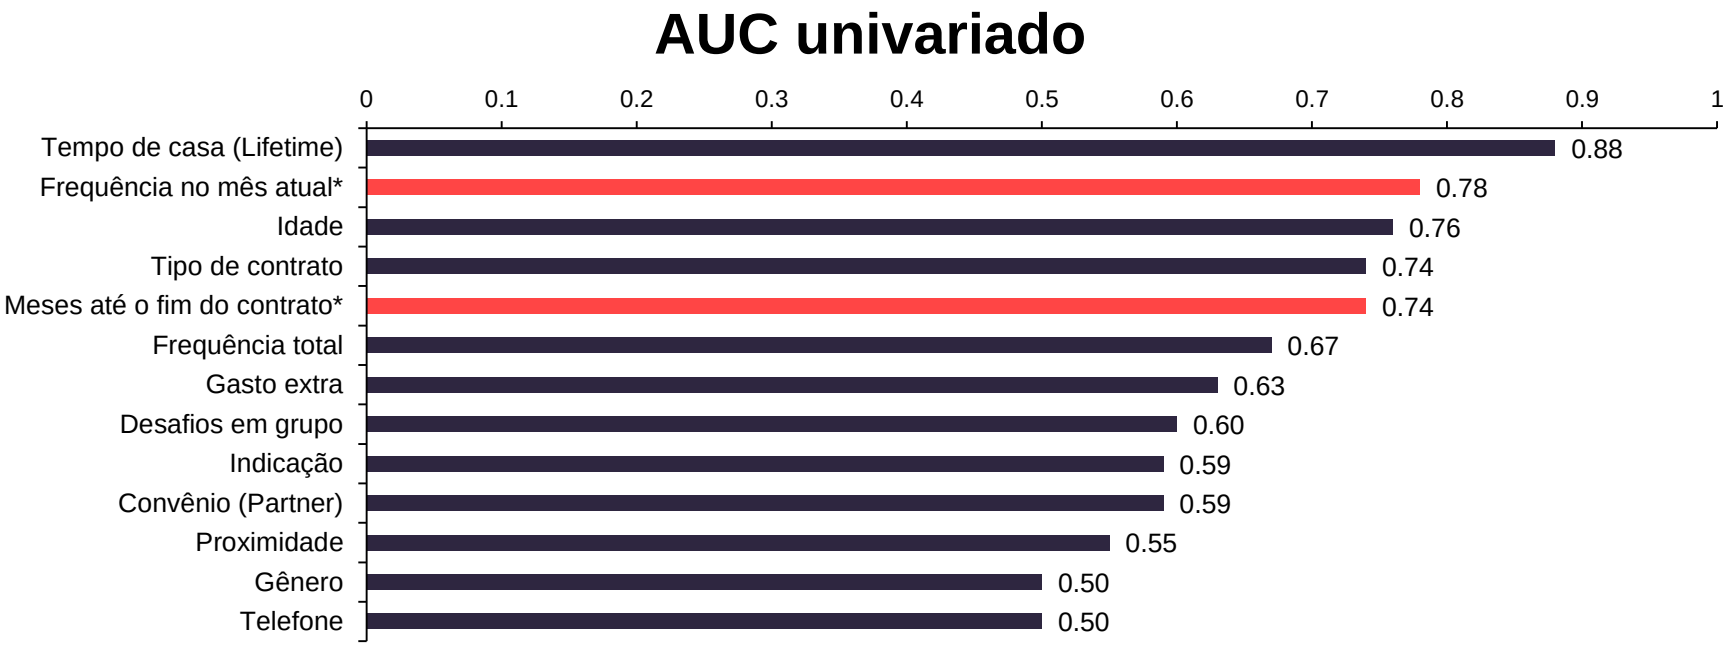
Galhos devem ser mutuamente exclusivos (MECE): não se sobrepõem e cobrem o problema.

Dos galhos às colunas do arquivo

Galho	Colunas no arquivo	Exemplo de hipótese
Características de entrada	Age · gender · Phone · Near_Location	O perfil de entrada prevê o cancelamento?
Comportamento de uso	Avg_class_frequency_total · _current_month · Avg_additional_charges_total	A queda de frequência antecede o cancelamento?
Ciclo de vida e contrato	Lifetime · Contract_period · Month_to_end_contract	O churn se concentra nos primeiros meses?
Comunidade e social	Group_visits · Promo_friends · Partner	Participar de grupos reduz o churn?

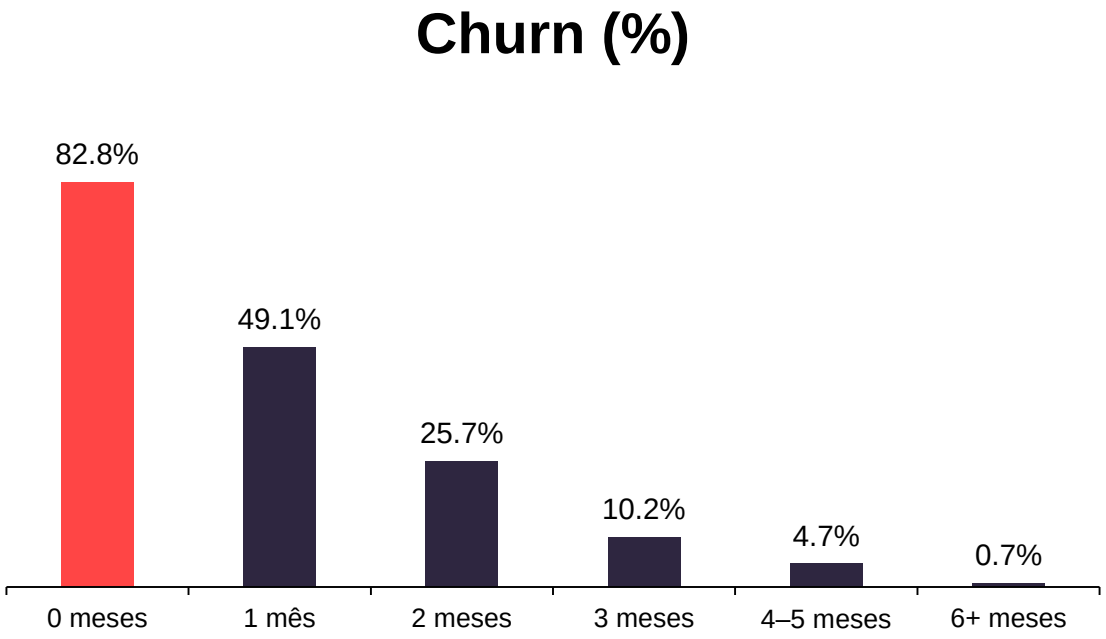
Atenção: Avg_class_frequency_current_month e Month_to_end_contract exigem cuidado (slide 12).

Revelação: qual variável separa quem cancela?



AUC: 0,50 = acaso; 1,00 = separa perfeitamente. * Cuidado: possível vazamento ou efeito do contrato. Tempo de casa: confirmar se foi medido até o cancelamento (se sim, é consequência). n = 4.000.

Tempo de casa: o início é o momento crítico



Churn por meses de casa (Lifetime). Base: 4.000 assinantes.

Leitura

1.330 usuários têm até 1 mês de casa.

817 deles cancelaram: 77% de todo o churn.

Depois de 6 meses, o churn é quase zero.

Idade prevê churn. Mas é a idade ou o tempo de casa?

Faixa etária	Churn entre 2 e 5 meses de casa	Usuários (n)
18–22 anos	55,0%	20
23–25 anos	39,8%	161
26–28 anos	18,8%	480
29–31 anos	9,5%	609
32–35 anos	3,5%	431
36 anos ou mais	0,0%	55

Amostras pequenas nas faixas extremas (18–22: n = 20). Não generalizar.

O que isso mostra

Mesmo com o tempo de casa fixo, idade continua separando quem cancela.

Correlação entre idade e tempo de casa: 0,16 (baixa).

O mecanismo (renda, uso, maturidade?) não está no arquivo.

Três armadilhas que vão aparecer hoje

Vazamento

Frequência do mês atual: 134 cancelados têm zero no mês.

Média: 1,04 entre cancelados; 2,03 entre ativos.

Essa medida existia antes do cancelamento? Não sabemos.

Sinal do contrato

Meses até o fim do contrato é sempre 1 no contrato mensal.

Não é um sinal independente: é, em boa parte, o tipo de contrato de novo.

Interprete sempre junto com o contrato.

Causalidade

Quem participa de desafios cancela menos (6,7% contra 18,6%, entre 2 e 5 meses).

Mas quem já é engajado tende a participar.

Correlação não prova que o desafio causa retenção.

Regra: use só variáveis que já existiam antes do cancelamento, e diga o que cada uma não mede.

Breakout: três perguntas (5 minutos)

Pergunta	O que registrar no documento compartilhado
(a) É a idade ou o tempo de casa?	Evidência (tabela 10) · Limitação · Próxima análise
(b) O contrato anual retém, ou quem fica escolhe anual?	Evidência · Por que a base não separa isso · Como testar
(c) Desafios ajudam, ou só atraem engajados?	Evidência (2 a 5 meses) · Como separar seleção de efeito

Cada grupo responde uma pergunta e registra uma hipótese com critério de refutação.

Plenária: o que sobreviveu, o que caiu?

1. Qual hipótese sobreviveu? Qual critério você usou?
2. Qual hipótese caiu? O que a derrubou?
3. Qual coluna você não usaria, e por quê?

Tempo: 10 minutos. Cada grupo fala no máximo 2 minutos.

Antes de agir: quem pode guiar uma decisão?

Podemos usar idade para decidir uma oferta?

Não sem debate. Pode gerar discriminação.

Usar idade para entender é diferente de decidir?

Sim. Entender o problema não é autorizar a ação.

O cliente pode contestar uma decisão automatizada?

Sim, pela LGPD (art. 20): pedir revisão.

LGPD, art. 6º, IX: não discriminação, ou seja, nenhum tratamento para fins discriminatórios ilícitos ou abusivos.

Gênero e telefone: sem poder preditivo nesta base. Não há razão para usá-los.

Fechamento

1. Hipótese boa: afirmação causal, métrica e critério de refutação.
2. Toda variável tem data: pergunte se ela existia antes do cancelamento.
3. Prever não é autorizar ação. Sempre há uma decisão humana e um critério ético.

Tarefa para terça (27/10)

Para cada galho: a coluna usada, a hipótese, e o que essa coluna não mede.

Próximo encontro: Aula 3, segmentação comportamental × demográfica.

MBA em **IA** e **Dados** para Negócios

Inteligência de Mercado e Modelagem Preditiva para Crescimento

inteli MBA