Aula 2 · Limpeza e Análise Exploratória de Dados

Trilha de Tecnologia

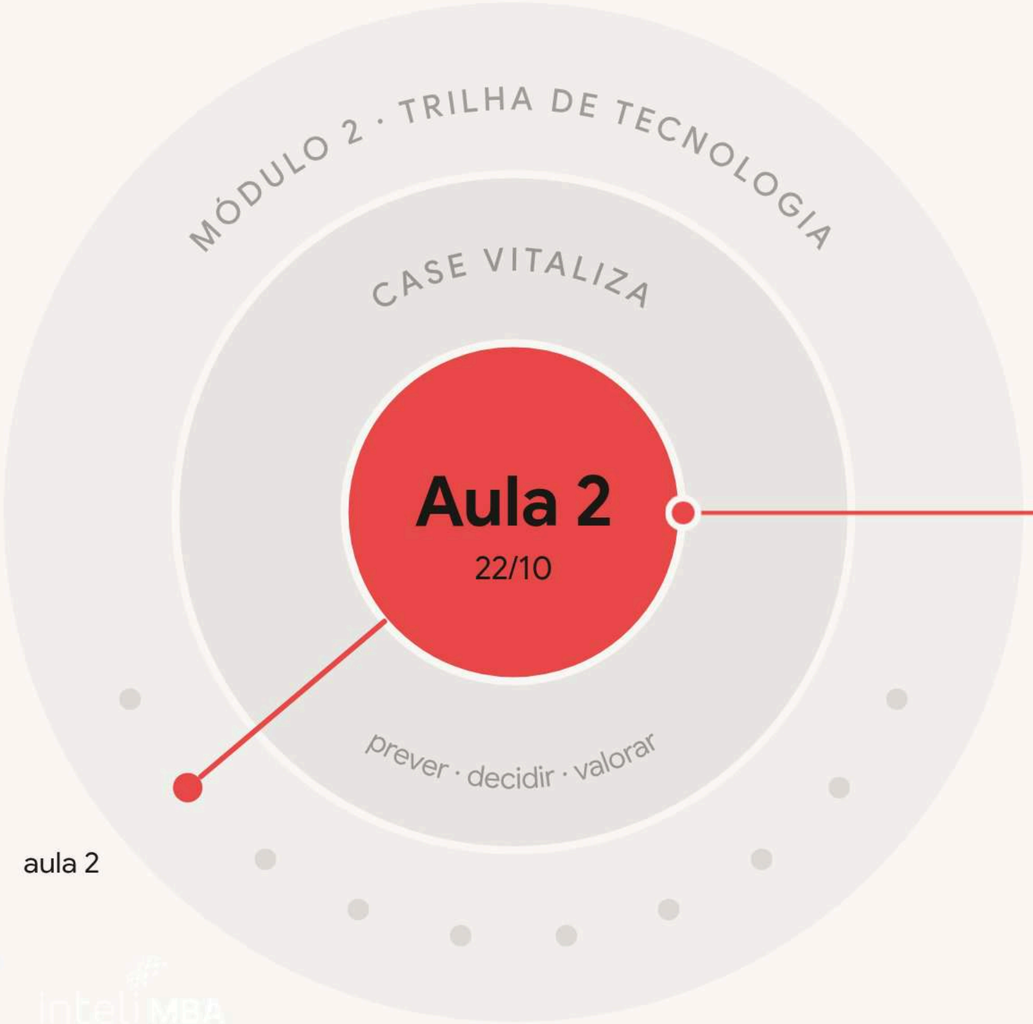
22 de outubro de 2026
MBA em IA e Dados para Negócios
Módulo 2

inteli inteli MBA

AULA 2 · 22/10

Do módulo à aula de hoje

O que a turma sai sabendo fazer



aula 2

AULA 2 · 22/10

Limpeza e análise exploratória

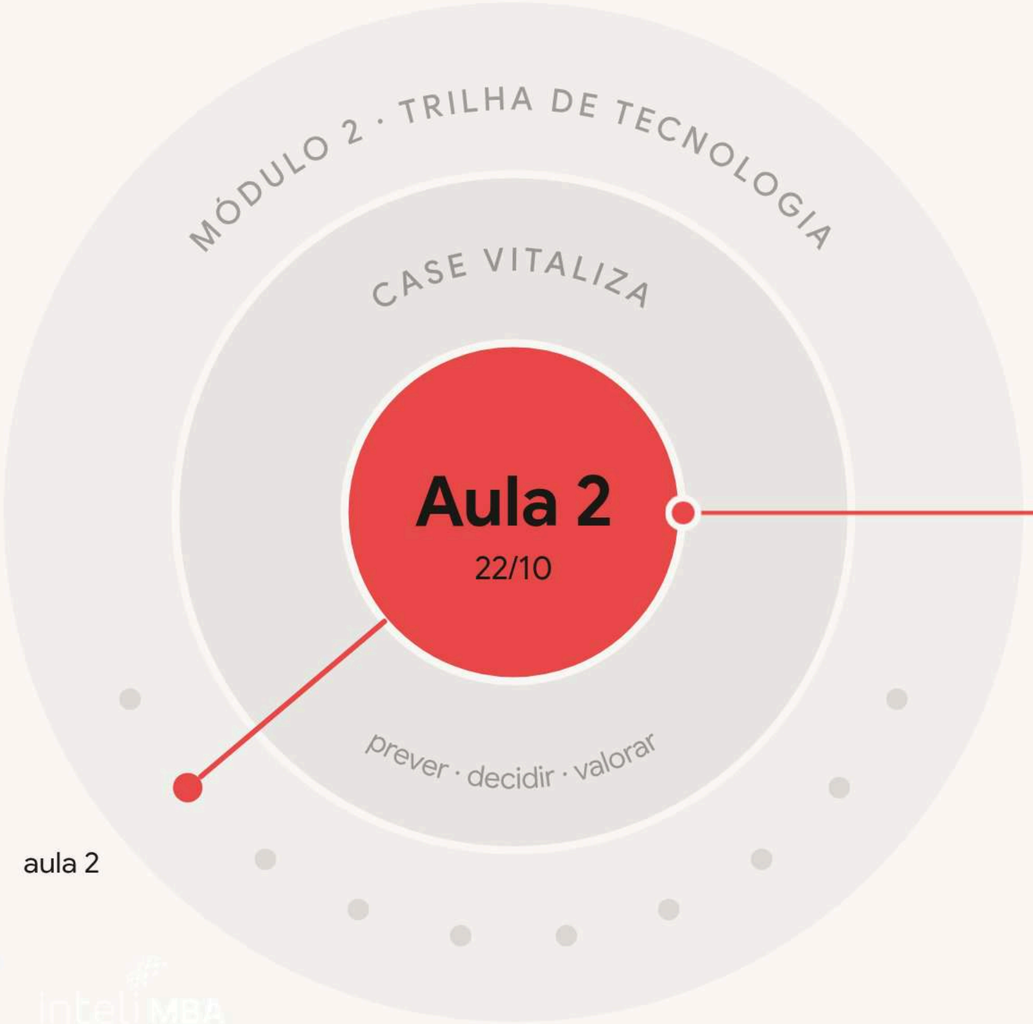
Ao sair daqui, vocês conseguem

1. **Montar um ambiente de análise** com um agente de código (Claude Code ou Codex) e um arquivo de contexto do projeto
2. **Pedir ao agente com método** e conferir o que ele produz
3. **Diagnosticar a qualidade de um arquivo** pelas cinco dimensões
4. **Descrever a base com estatística descritiva** e reconstruir a situação de um assinante numa data
5. **Testar uma hipótese de negócio** com um cruzamento

AULA 2 · 22/10

Do módulo à aula de hoje

Como a aula anda



aula 2

AULA 2 · 22/10

Três capítulos

1 **O ambiente**
Um agente de código, uma pasta e as regras do grupo

2 **Análise exploratória**
O que olhar, em que ordem e como confiar no número

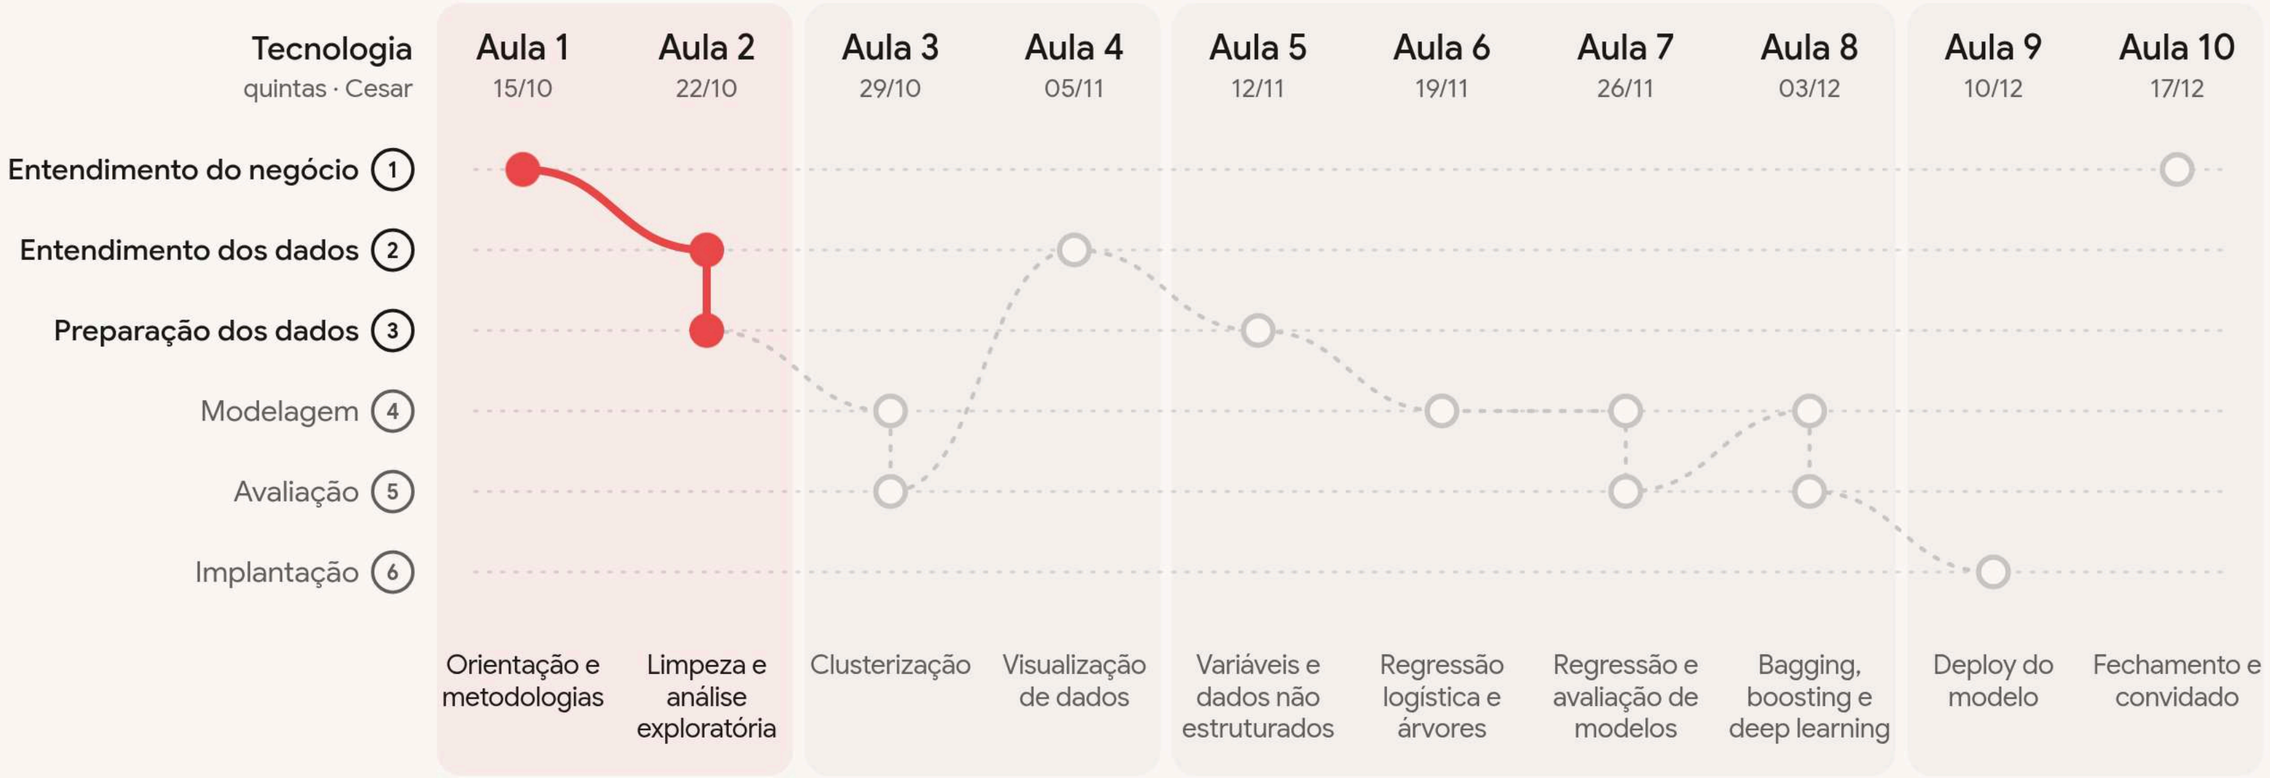
3 **Na prática**
Quatro missões, três funções, um registro

No fim · a base integrada no corte e o registro de decisões do grupo

O MÓDULO: DEZ AULAS NO CICLO DO CRISP-DM

A linha anda pelo ciclo, não desce uma escada

Qual é o problema e o que os dados dizem?



Negócios
terças · Fábio

orientação

1º MOVIMENTO · ENTENDER

Hipótese analítica | Segmentação | Storytelling e personas | Valor vs. risco

checkpoint

2º MOVIMENTO · AGIR

Da predição à ação | Intervenção com GenAI | ROI da retenção

convidado

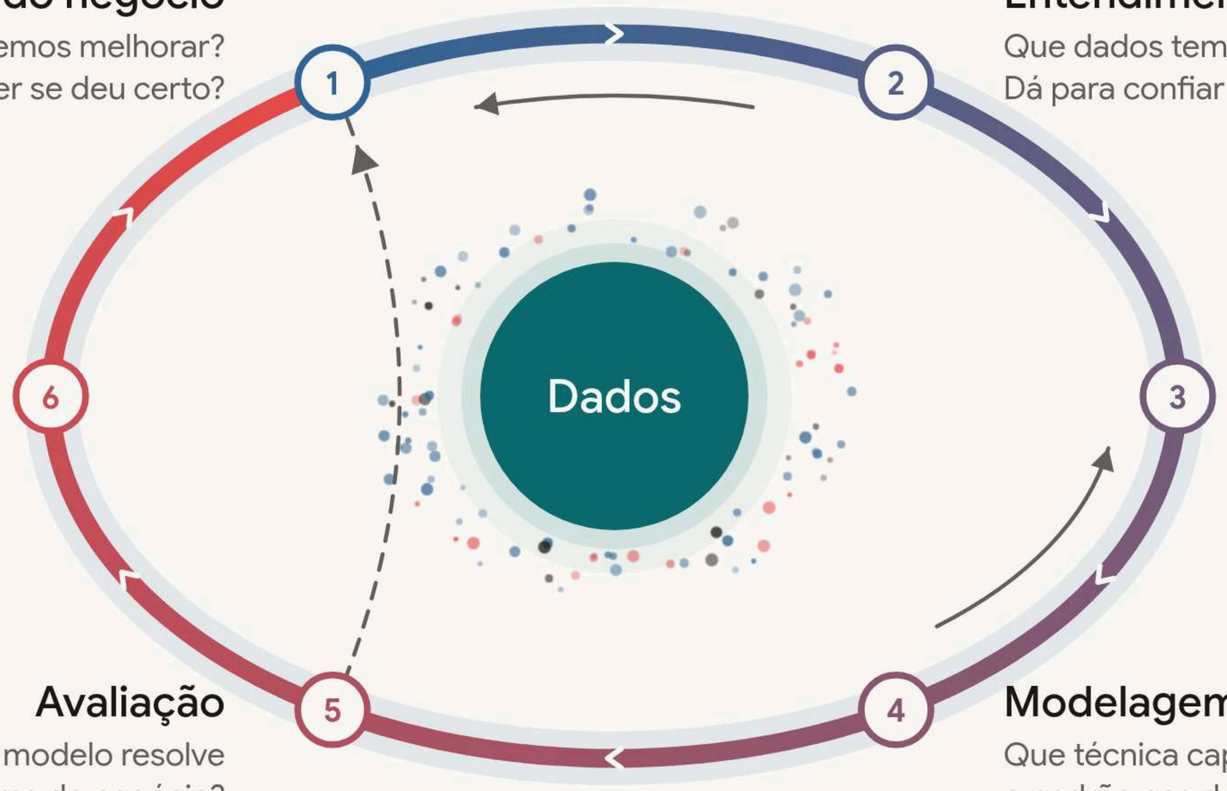
inteli

inteli MBA

FUNDAMENTOS

CRISP-DM: seis fases que vão e voltam

Cross-Industry Standard Process for Data Mining (2000): um roteiro aberto de projeto de dados, para qualquer setor



1 Entendimento do negócio
Que decisão queremos melhorar?
Como saber se deu certo?

2 Entendimento dos dados
Que dados temos?
Dá para confiar neles?

3 Preparação dos dados
Como os arquivos viram
a tabela que o modelo lê?

4 Modelagem
Que técnica captura
o padrão nos dados?

5 Avaliação
O modelo resolve
o problema do negócio?

6 Implantação
Como o resultado entra
na rotina da empresa?

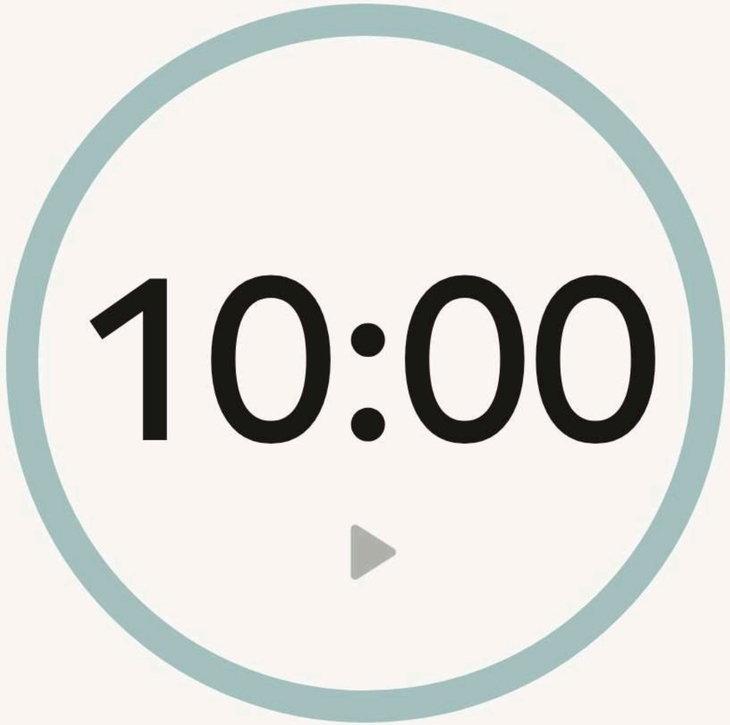
CHAPMAN et al. (2000); WIRTH; HIPP (2000)

ABERTURA · AULA 2

Salve-se quem puder

Quanto a Vitaliza faturou em setembro de 2026?

- Vale qualquer ferramenta
- Base: **pagamentos.csv**



ABERTURA · AULA 2

Os números da turma

Quanto a Vitaliza faturou em setembro de 2026?

26 pessoas responderam



Coleta fechada Abrir Zerar

ABERTURA · AULA 2

Como vocês chegaram a esse número?

IMPROVISADO

Sem método ou sem resposta

Respostas sem cálculo ou sem explicação, apenas um valor, um chute ou o nome de uma ferramenta usada.

John

Marcos Antonio Da Silva

Cesar · Henrique

Thiago · +2

IMPROVISADO

Tratamento genérico com IA

Jogaram a base em uma IA com prompt amplo pedindo para limpar dados, tratar erros e informar o valor líquido.

Gabriela Bueno

Marcelo Tagliari

Douglas Tostes

Gabriel Rodrigues · +6

PARCIAL

Filtro e descontos sem detalhe

Trataram formatos, fuso e duplicidades, filtraram aprovados e subtraíram estornos e chargebacks, com cálculo pouco detalhado.

Fernando · Johntan

Vítor Lima · Pedro Martinez

Isabela · Ricardo Terzian

Camila

METÓDICO

Competência com distribuição mensal e anual

Padronizaram a base, distribuíram pagamentos mensais e anuais ao longo da vigência e compararam com o valor transacional.

Igor Oliveira

ABERTURA · AULA 2

Onde os números se separam

O número importa menos que o caminho

Só o que foi aprovado? R$ 509.588 → R$ 499.503
recusadas, estornos e chargebacks

Em que horário? → R$ 499.402
UTC contra Brasília

Cobrou duas vezes? → R$ 492.572
retentativas aprovadas em dobro

Bruto ou líquido? → R$ 436.442
taxas das lojas, do cartão e do Pix

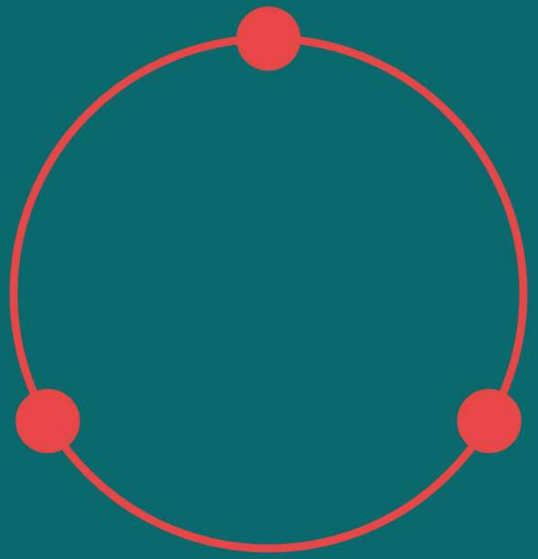
R$ 436.442

líquido em setembro de 2026, ou R$ 492.572 bruto

1

O ambiente

Um agente de código, uma pasta e as regras do grupo



HARNESS

O modelo é o motor; o harness é o resto

Claude Code e Codex são dois harnesses para trabalhar com código.



- Ferramentas
- Arquivos
- Permissões
- Memória

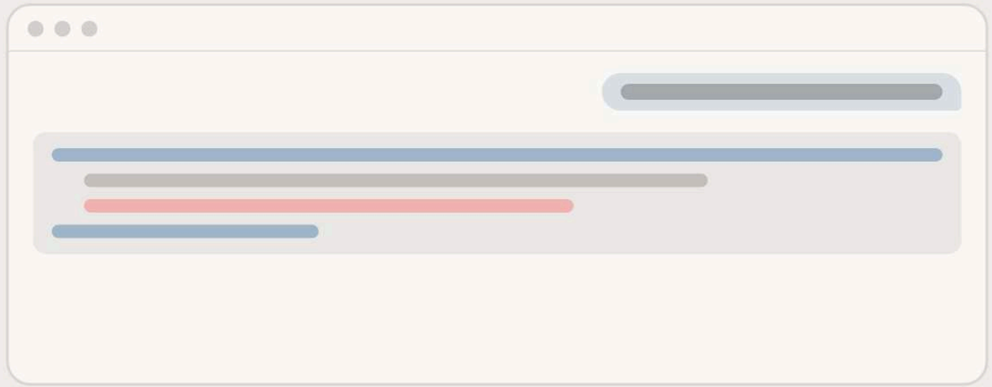
HARNESS

Do chat ao agente

O ciclo é planejar, executar e conferir.

Chat

responde



Agente

Claude Code · Codex

- Lê os arquivos da pasta
- Escreve e roda código
- Olha o resultado
- Corrige

Planejar → Executar → Conferir

O AMBIENTE

A pasta do projeto

O desenho da pasta já é uma regra: o bruto nunca é editado.

vitaliza-grupo-XX/	
AGENTS.md	(ou CLAUDE.md)
decisoes.md	
docs/	enunciado e dicionário de dados
dados/	
brutos/ só leitura	os 12 arquivos e heatmaps_90d/
processados/	tabelas intermediárias do grupo
notebooks/	
src/	
saidas/	
.gitignore	dados/ e .env fora do repositório

O AMBIENTE

As duas ferramentas lado a lado

Claude Code

Instalação pelo terminal

macOS e Linux

```
curl -fsSL https://claude.ai/install.sh | bash
```

PowerShell

```
irm https://claude.ai/install.ps1 | iex
```

ou app de desktop

Exige conta Pro, Max, Team, Enterprise ou Console.

Lê o `CLAUDE.md` do projeto.

Codex

Instalação pelo terminal

macOS e Linux

```
curl -fsSL https://chatgpt.com/codex/install.sh | sh
```

ou extensão de IDE ou app de desktop

Entra com a conta do ChatGPT, incluído em todos os planos com limites diferentes.

Lê o `AGENTS.md`, que o comando `/init` cria.

O AMBIENTE

Git como rede de segurança

Um commit antes de cada pedido grande deixa desfazer o que o agente fez.

```
vitaliza-grupo-XX/
  AGENTS.md
  decisoes.md
  docs/
  dados/
    brutos/   só leitura
    processados/
  notebooks/
  src/
  saidas/
  .gitignore
```

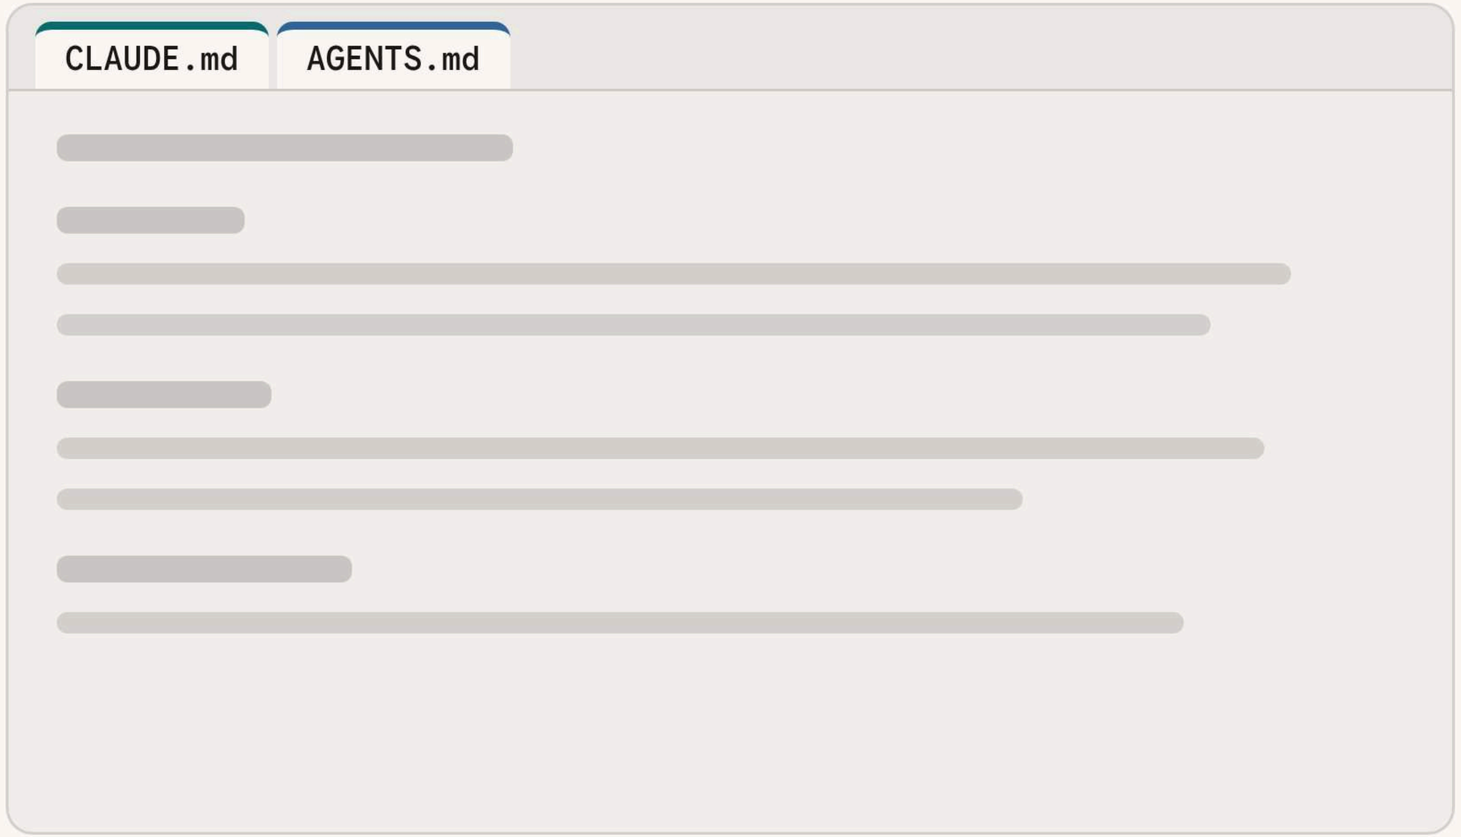


O **`.gitignore`** tira os dados e qualquer arquivo de chave do repositório.

O AMBIENTE

O que é o arquivo de contexto

Um arquivo de texto na raiz do projeto que o agente lê no começo de cada sessão.



`CLAUDE.md` Claude Code

`AGENTS.md` Codex

Mesma ideia, dois nomes.

O AMBIENTE

O que entra para a Vitaliza

CLAUDE.md | AGENTS.md

```
# Projeto Vitaliza · grupo XX

## O case
A Vitaliza é um app de assinatura para quem treina. O grupo estuda a saída
de assinantes: quem sai, por quê e em quem vale a pena agir. Enunciado e
dicionário de dados estão em docs/.

## Os dados
- Os arquivos originais estão em dados/brutos/. Nunca altere, mova ou
  apague esses arquivos.

- Data de corte: 30/09/2026. Nenhuma análise usa informação posterior ao
  corte.

## Como trabalhar
- Antes de uma tarefa com mais de um passo, apresente o plano e espere a
  aprovação.

…
```

- o case em três linhas
- onde estão os dados e o dicionário
- a data de corte
- as regras do grupo

O AMBIENTE

O que não entra

CLAUDE.md | AGENTS.md

```
## Como trabalhar
- Antes de uma tarefa com mais de um passo, apresente o plano e espere a
  aprovação.

…

## O que não fazer
- Não coloque chaves de API, senhas ou tokens em nenhum arquivo do projeto.
- Não processe o data room inteiro de uma vez: use só os arquivos que a
  pergunta da vez pede.
```

- ✕ Chaves de API
- ✕ Senhas
- ✕ Respostas prontas
- ✕ Textos longos que o agente não precisa ler a cada tarefa

O AMBIENTE

O primeiro pedido

O agente lê o arquivo de contexto e propõe o inventário antes de abrir os dados.

OBJETIVO

Ver se o agente segue o AGENTS.md antes de tocar nos dados e saber o que há em cada arquivo.

PROMPT

```
Leia o AGENTS.md antes de começar.
Quero um inventário de dados/brutos/, sem alterar nada.
Para cada arquivo: linhas, colunas, tipos e vazios.
Em heatmaps_90d/, só quantos arquivos há e o formato.
Compare com o dicionário em docs/ e liste as divergências.
Antes de executar, mostre o plano e espere a aprovação.
Salve em saidas/inventario.md, uma seção por arquivo.
```

CONFIRA

- O plano vem antes de qualquer comando e repete as regras do AGENTS.md, como o corte em 30/09/2026.
- Uma seção para cada um dos 12 arquivos de dados.
- usuarios.csv com 64.948 linhas (o wc -l dá 64.949, com o cabeçalho); atividades.parquet com 1.254.475.
- Nada mudou em dados/brutos/.

O AMBIENTE

Prática: Configurando o ambiente do grupo

15 minutos, em grupo

1 Criar a pasta

`vitaliza-grupo-XX` em Documentos, fora do OneDrive e do iCloud

2 Abrir no agente

Claude Code ou Codex na pasta, e o pedido que monta o projeto

3 Colocar os dados

O agente junta os zips em `dados/brutos/`, só leitura

4 Ambiente Python

O agente cria o ambiente e testa a leitura dos dados

5 Conta e token

Conta no GitHub e o token guardado no `.env`, nunca no chat

6 Criar o repositório

O agente cria o repositório privado e envia, sem os dados

7 Os colegas entram

Cada um com o próprio token, pelo pedido do roteiro

8 Pedir o inventário

Cada arquivo comparado com o dicionário, em `saidas/inventario.md`

9 Salvar e enviar

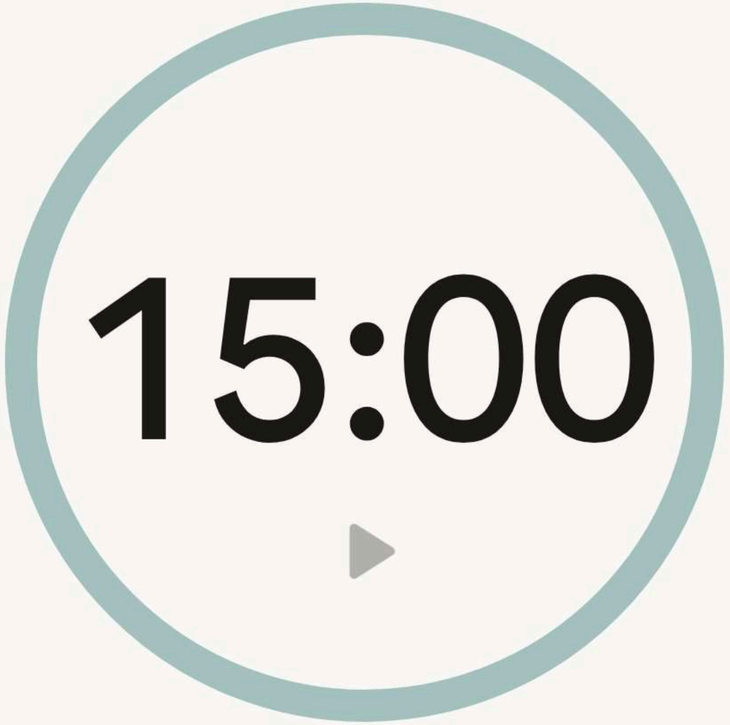
O agente faz o commit e o push do trabalho do grupo

O AMBIENTE

Prática: Configurando o ambiente do grupo

15 minutos, em grupo

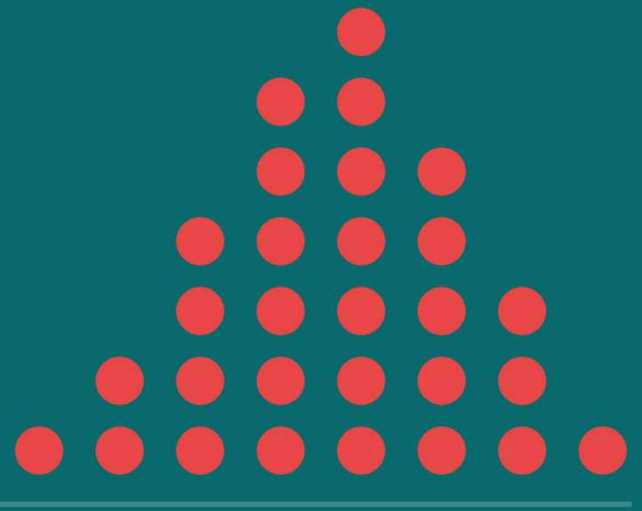
1. Criar a pasta `vitaliza-grupo-XX`
2. Abrir no Claude Code ou no Codex e montar o projeto
3. O agente coloca os dados em `dados/brutos/`
4. O agente cria o ambiente Python
5. Conta no GitHub e token no `.env`
6. O agente cria o repositório e envia
7. Os colegas entram pelo agente
8. Pedir o inventário: `saidas/inventario.md`
9. Salvar e enviar pelo agente



2

Análise exploratória

O que olhar, em que ordem e como confiar no número



Sprint ou maratona?

Análise exploratória é maratona, com etapas e pontos de controle, não um pedido único.



"Sprints"

Tarefas simples, diretas, genéricas, rápidas, pontuais



"Maratona"

Tarefas complexas que requerem contexto, aprofundamento, reflexão, múltiplas etapas de trabalho

O AMBIENTE · PEDIR E CONFERIR

A anatomia de um pedido

Pedir o plano antes da execução.

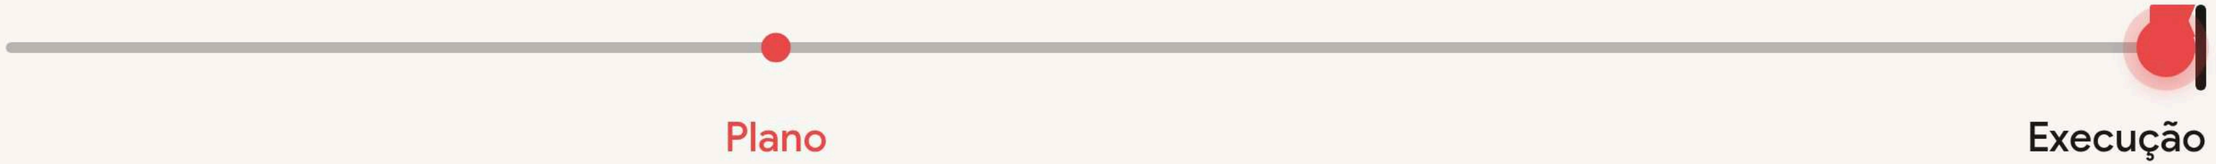
1
A pergunta

2
Os arquivos que ela pede

3
As regras

4
O formato da saída

5
O critério de pronto



O AMBIENTE · PEDIR E CONFERIR

Conferir antes de acreditar

O agente responde com a mesma segurança quando acerta e quando junta o retrato de 01/10 com o histórico.

- ✓ **Ler o código**
- ✓ **Rodar de novo**
- ✓ **Checar três números à mão**
- ✓ **Comparar com o dicionário**



O AMBIENTE · PEDIR E CONFERIR

Um pedido completo

A contagem de pagantes ativos no corte, nas cinco partes do pedido.

OBJETIVO

Contar os pagantes ativos no corte com um pedido nas cinco partes e conferir o número antes de acreditar.

PROMPT

```
Pergunta: quantos assinantes pagantes ativos a Vitaliza tinha
no corte, 30/09/2026?
Arquivos: dados/brutos/assinaturas.csv e
dados/brutos/usuarios.csv, com o dicionário em docs/.
Regras: contas de teste (e-mail @vitaliza.com.br) não contam;
mostre as linhas depois de cada filtro; não altere nada em
dados/brutos/.
Saída: o número, a tabela de filtros e o código em notebooks/.
Pronto quando: a soma por plano e por canal bate com o total.
Antes de rodar, mostre o plano e espere a aprovação.
```

CONFIRA

- 14.753 pagantes ativos, o número do LEIA-ME.
- Anual 57% e mensal 43%; App Store 36,6% e Google Play 33,6%.
- Armadilha: 14.813 é o retrato sem tirar as 60 contas de teste.
- Cheque à mão três contas do resultado.

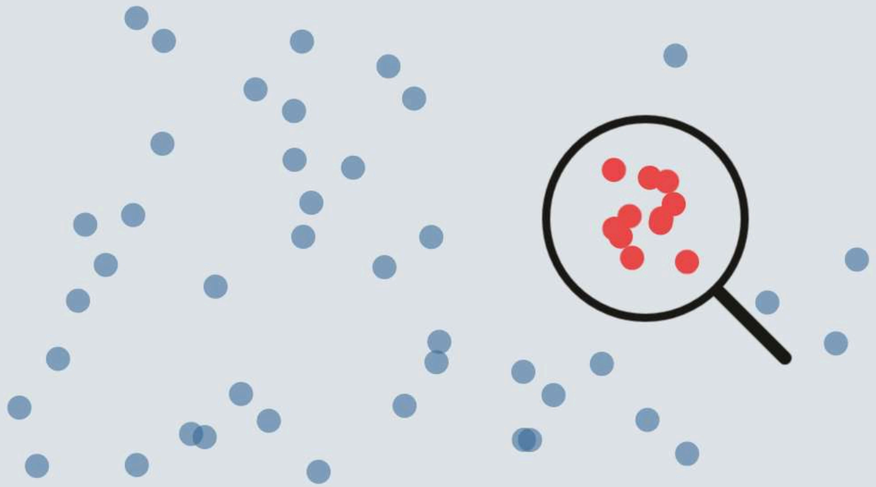
ANÁLISE EXPLORATÓRIA · O QUE É

Detetive antes do juiz

Análise exploratória procura o que os dados mostram; análise confirmatória testa o que já se suspeita.

Exploratória

o detetive



Confirmatória

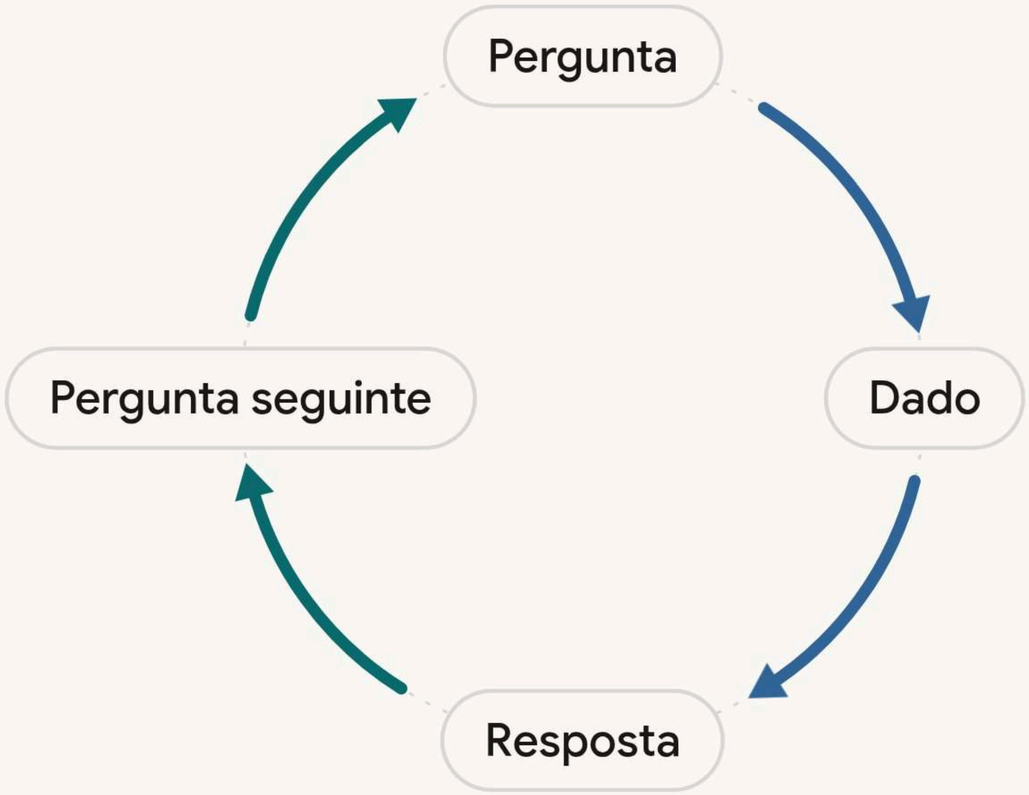
o juiz



TUKEY (1977)

O ciclo da exploração

Em 2026, o agente acelera a parte mecânica; escolher a pergunta e julgar a resposta continua com o grupo.

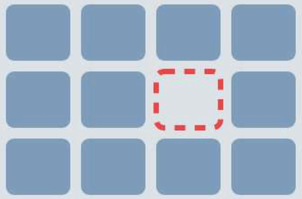


Agente
a parte mecânica

Grupo
a pergunta e o julgamento

Cinco dimensões da qualidade

A partir da pesquisa com usuários de dados de Wang e Strong (1996).



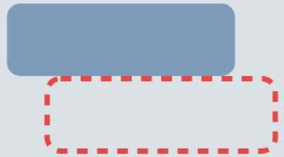
Completude



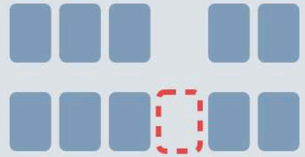
Validade



Consistência



Unicidade



Temporalidade

ANÁLISE EXPLORATÓRIA · QUALIDADE

Um exemplo da base por dimensão

Os exemplos vêm de onboarding.csv, atividades.parquet e uso_mensal.csv.

Completude	**8,6%** `onboarding.csv`	das respostas do onboarding não têm o objetivo preenchido
Validade	**951 treinos** `atividades.parquet`	com mais de 200 km, e um de 10.013 km, para uma mediana de 6,5 km; 3.649 treinos têm duração zero
Consistência	**corrida · run** `atividades.parquet`	o mesmo tipo de treino aparece em português e em inglês, como caminhada e walk
Unicidade	**9.383 treinos** `atividades.parquet`	chegaram duas vezes, uma pelo app e outra pelo relógio (garmin ou apple_health)
Temporalidade	**ausente · zero** `uso_mensal.csv`	mês sem uso é linha ausente em 2025 e linha com zero em 2026

WANG; STRONG (1996)

ANÁLISE EXPLORATÓRIA · QUALIDADE

Completude | Validade | Consistência | Unicidade | Temporalidade

Completude: 8,6% sem objetivo

onboarding.csv: 5.467 das 63.929 respostas não têm objetivo_texto.

OBJETIVO

Medir quanto falta em cada coluna e separar o vazio opcional do vazio que é problema.

PROMPT

```
Leia docs/dicionario_dados.md.
Mostre o plano antes de rodar.
Em dados/brutos/onboarding.csv:
1. conte as linhas e os user_id únicos;
2. em cada coluna, conte os vazios: nulos e textos só com
espaços, separados;
3. mostre o percentual, da coluna mais vazia para a menos
vazia;
4. diga quais colunas o dicionário marca como opcionais.
Não altere nada em dados/brutos/.
```

CONFIRA

- 63.929 respostas, uma por conta.
- objetivo_texto: 5.467 vazias (8,6%), todas nulas; nenhuma só com espaços.
- Opcionais no dicionário: objetivo_texto e como_conheceu.
- Armadilha: nivel (7,1%) e dias_por_semana (10,0%) também têm vazios, e o dicionário não diz que são opcionais.

ANÁLISE EXPLORATÓRIA · QUALIDADE

Completude | Validade | Consistência | Unicidade | Temporalidade

Validade: 951 treinos acima de 200 km

atividades.parquet: um treino de 10.013 km para uma mediana de 6,5 km, e 3.649 com duração zero.

OBJETIVO

Achar distâncias e durações de treino que não podem ser reais, sem confundir com o que só está vazio.

PROMPT

```
Leia docs/dicionario_dados.md.
Mostre o plano antes de rodar.
Em dados/brutos/atividades.parquet (pandas e pyarrow):
1. conte os treinos e quantos têm distancia_km preenchida;
2. mostre mínimo, mediana e máximo de distancia_km e
duracao_min;
3. conte os treinos acima de 200 km e os com duração zero ou
negativa;
4. liste os cinco mais longos, com todas as colunas.
Não altere nada em dados/brutos/.
```

CONFIRA

- 1.254.475 treinos; 679.640 com distância.
- Mediana 6,47 km; 951 acima de 200 km. O maior, 10.012,75 km, é um pedal de 160 minutos do apple_health.
- 3.649 treinos com duração zero; nenhum negativo.
- Armadilha: os 574.835 sem distância não são erro; não tinham GPS.

ANÁLISE EXPLORATÓRIA · QUALIDADE

Completude | Validade | **Consistência** | Unicidade | Temporalidade

Consistência: corrida e run

atividades.parquet: o mesmo tipo de treino aparece em português e em inglês.

OBJETIVO

Ver se a mesma categoria aparece escrita de mais de um jeito na coluna tipo.

PROMPT

```
Leia docs/dicionario_dados.md.
Mostre o plano antes de rodar.
Em dados/brutos/atividades.parquet:
1. liste os valores de tipo, com a contagem de cada um;
2. cruze tipo com origem;
3. aponte os valores que parecem a mesma categoria e proponha
um mapa de padronização, sem aplicar;
4. mostre quantas linhas cada troca afetaria.
Não altere nada em dados/brutos/.
```

CONFIRA

- 11 valores para 7 tipos: corrida e run, caminhada e walk, forca e strength, pedal e ride.
- Os nomes em inglês (376.930 treinos, 30%) vêm todos da origem app.
- Armadilha: contar só corrida deixa de fora 162.108 corridas.

Unicidade: 9.383 treinos em dobro

atividades.parquet: o mesmo treino chega pelo app e pelo relógio.

OBJETIVO

Contar os treinos que chegaram duas vezes, uma pelo app e outra pelo relógio.

PROMPT

```
Leia docs/dicionario_dados.md.
Mostre o plano antes de rodar e diga como vai tratar o horário
de cada origem.
Em dados/brutos/atividades.parquet:
1. ache os pares da mesma conta, mesmo tipo e mesma duração,
com início a até 5 minutos, um de origem app e outro de garmin
ou apple_health;
2. conte os pares por origem;
3. mostre cinco pares lado a lado.
Não remova nada nem altere dados/brutos/.
```

CONFIRA

- 9.383 pares: 4.184 com o apple_health e 5.199 com o garmin.
- Nos pares, a distância também é igual.
- Armadilha: o garmin grava o início 3 horas à frente (UTC). Sem corrigir o fuso, só aparecem os 4.184 do apple_health.

Temporalidade: ausente em 2025, zero em 2026

uso_mensal.csv: o mês sem treino muda de forma na virada do ano.

OBJETIVO

Ver se o mês sem treino é registrado do mesmo jeito em 2025 e em 2026, antes de comparar médias.

PROMPT

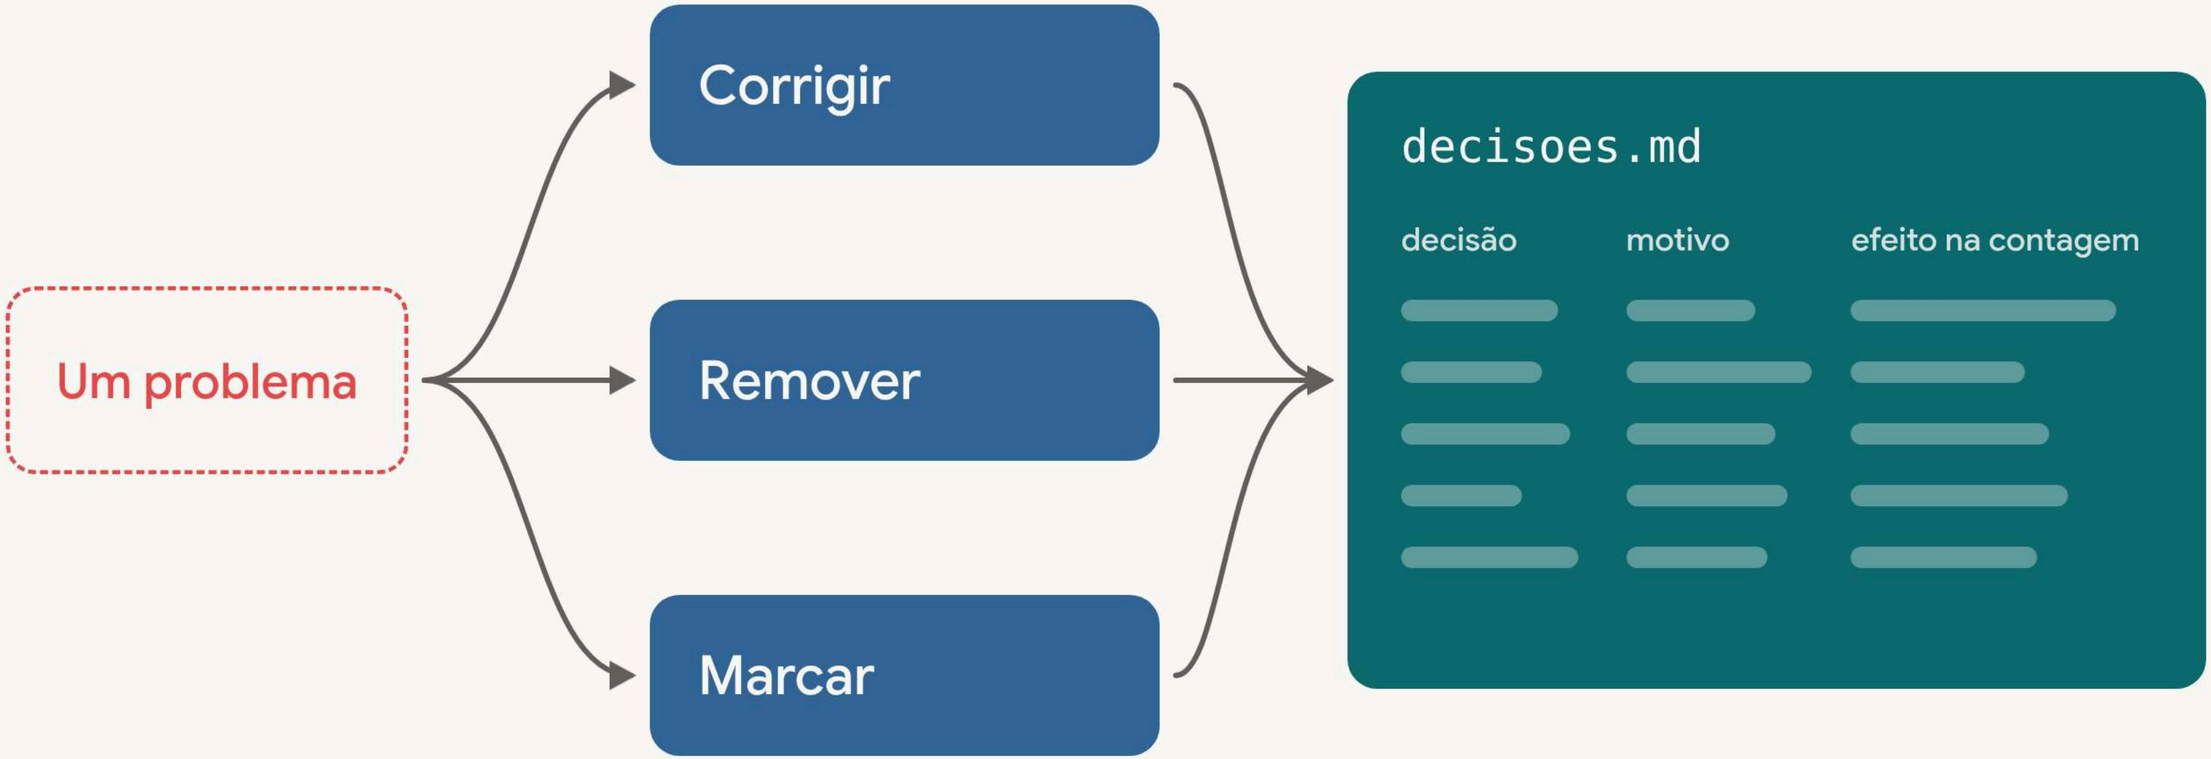
```
Leia docs/dicionario_dados.md.
Mostre o plano antes de rodar.
Em dados/brutos/uso_mensal.csv, para cada mês de jan/2025 a
set/2026:
1. conte as linhas e as linhas com minutos = 0;
2. calcule a média e a mediana de minutos;
3. explique o que muda na virada de 2025 para 2026 e o efeito
disso numa média calculada sobre o arquivo como está.
Não altere nada em dados/brutos/.
```

CONFIRA

- 2025: nenhum mês com linha zerada; dez/2025 tem 13.624 linhas.
- jan/2026: 41.130 linhas, 25.697 com zero.
- A média cai de 265 para 118 minutos na virada só por isso; contando só quem treinou, jan/2026 dá 314.

Limpar é decidir

Cada problema tem três saídas, e cada escolha entra em decisoes.md com o motivo e o efeito na contagem.



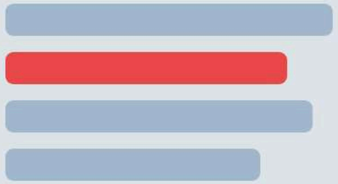
REDMAN (2016)

ANÁLISE EXPLORATÓRIA · GRANULARIDADE

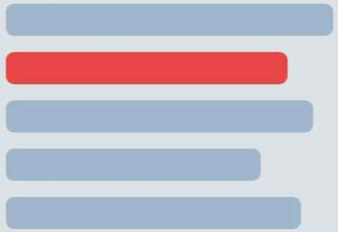
Uma linha por quê?

Cada arquivo tem sua granularidade, e uma tabela arrumada tem uma observação por linha.

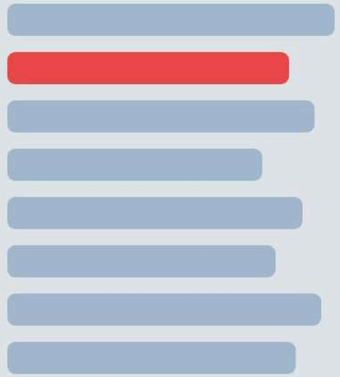
uma linha por
conta
usuarios.csv



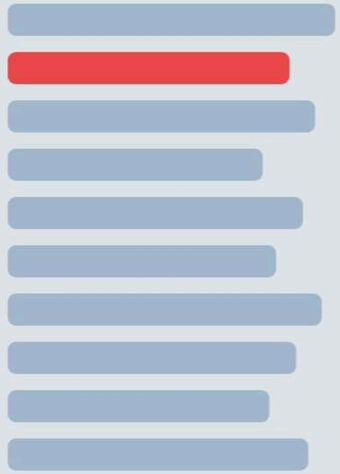
uma linha por
assinatura
assinaturas.csv



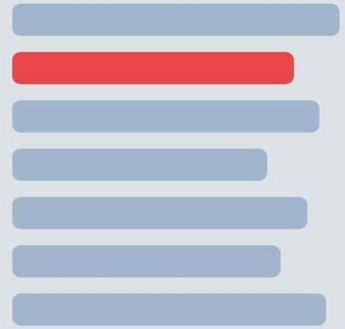
uma linha por
evento
eventos_assinatura.csv



uma linha por
treino
atividades.parquet



uma linha por
mês
uso_mensal.csv



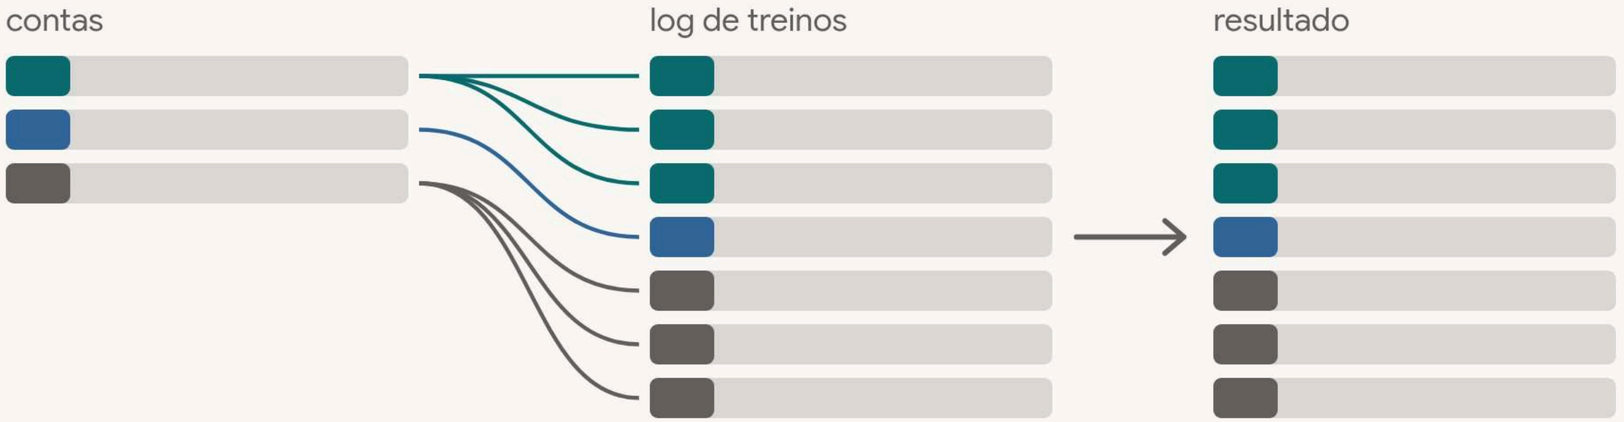
WICKHAM (2014)

ANÁLISE EXPLORATÓRIA · GRANULARIDADE

Juntar sem multiplicar

Resumir o log por assinante antes de juntar; contar as linhas antes e depois de cada junção.

Juntar o log direto um para muitos pelo user_id



3 → 7 linhas

as contas se repetem

Resumir antes de juntar um para um pelo user_id



3 → 3 linhas

uma linha por conta

ANÁLISE EXPLORATÓRIA · GRANULARIDADE

Na base: contar antes e depois

usuarios.csv e atividades.parquet, ligados pelo user_id.

OBJETIVO

Juntar os treinos às contas sem multiplicar linhas, contando antes e depois da junção.

PROMPT

```
Leia docs/dicionario_dados.md.
Mostre o plano antes de rodar, com o grão de cada arquivo.
Quero uma linha por conta de dados/brutos/usuarios.csv, com os
treinos e os minutos de dados/brutos/atividades.parquet:
1. conte as linhas de cada arquivo;
2. resuma os treinos por user_id antes de juntar;
3. junte pela esquerda e conte as linhas depois;
4. confirme que há um user_id por linha;
5. deixe com zero as contas sem treino.
Salve em dados/processados/. Não altere nada em dados/brutos/.
```

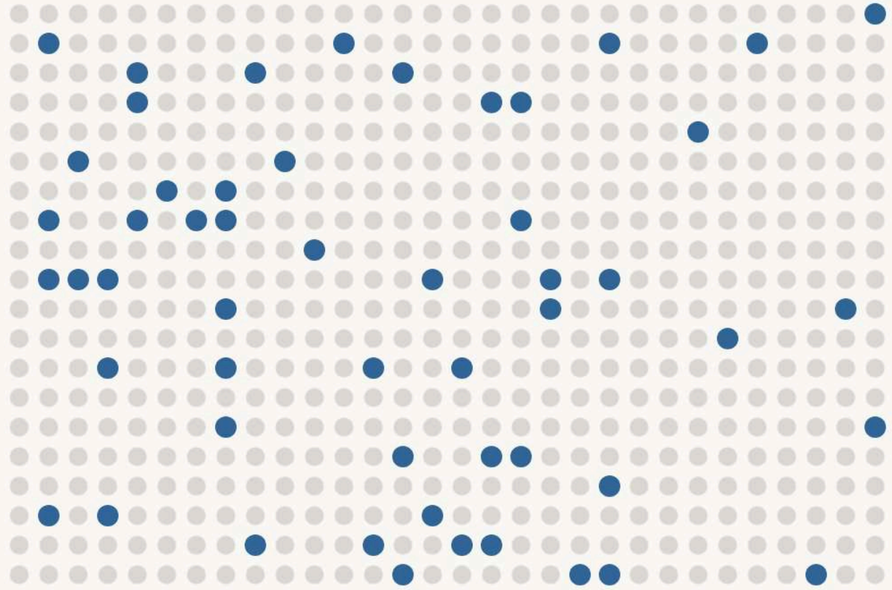
CONFIRA

- 64.948 contas e 1.254.475 treinos.
- Juntar o log direto daria 1.282.872 linhas: as contas se repetem.
- Resumindo antes: 36.551 contas com treino; depois da junção, 64.948 linhas, 28.397 com zero.
- Armadilha: mais linhas que contas no resultado é sinal de que a junção multiplicou.

Cada amostra dá uma média diferente

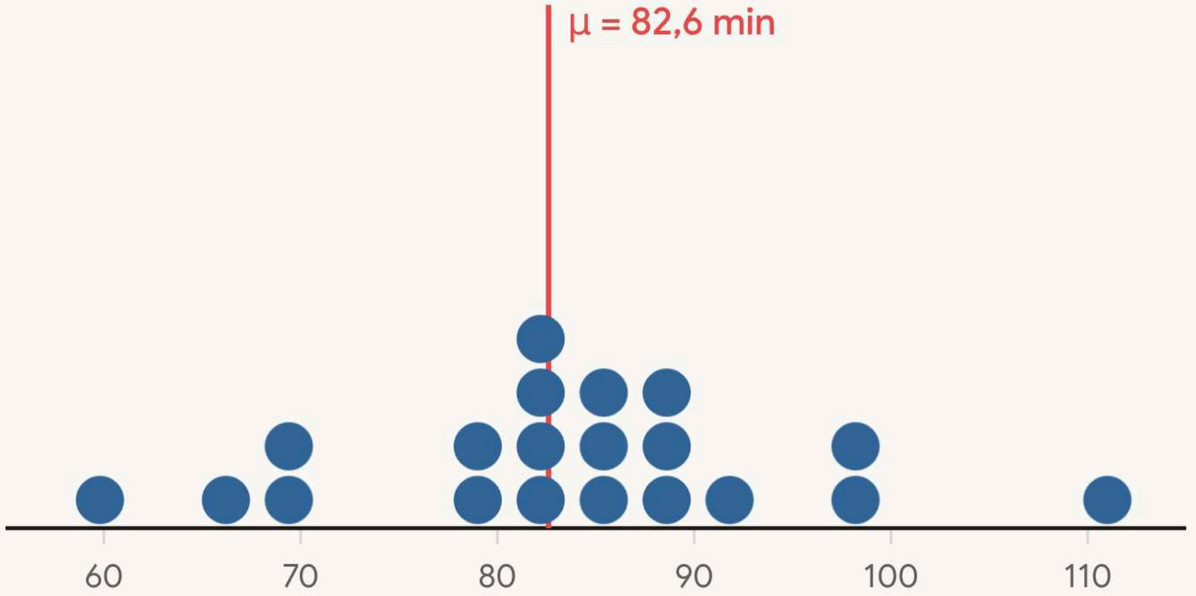
Minutos de treino por conta em setembro de 2026: a base inteira e 20 sorteios de 500 contas.

População: 56.565 contas



sorteio de 500 contas

Média de cada sorteio



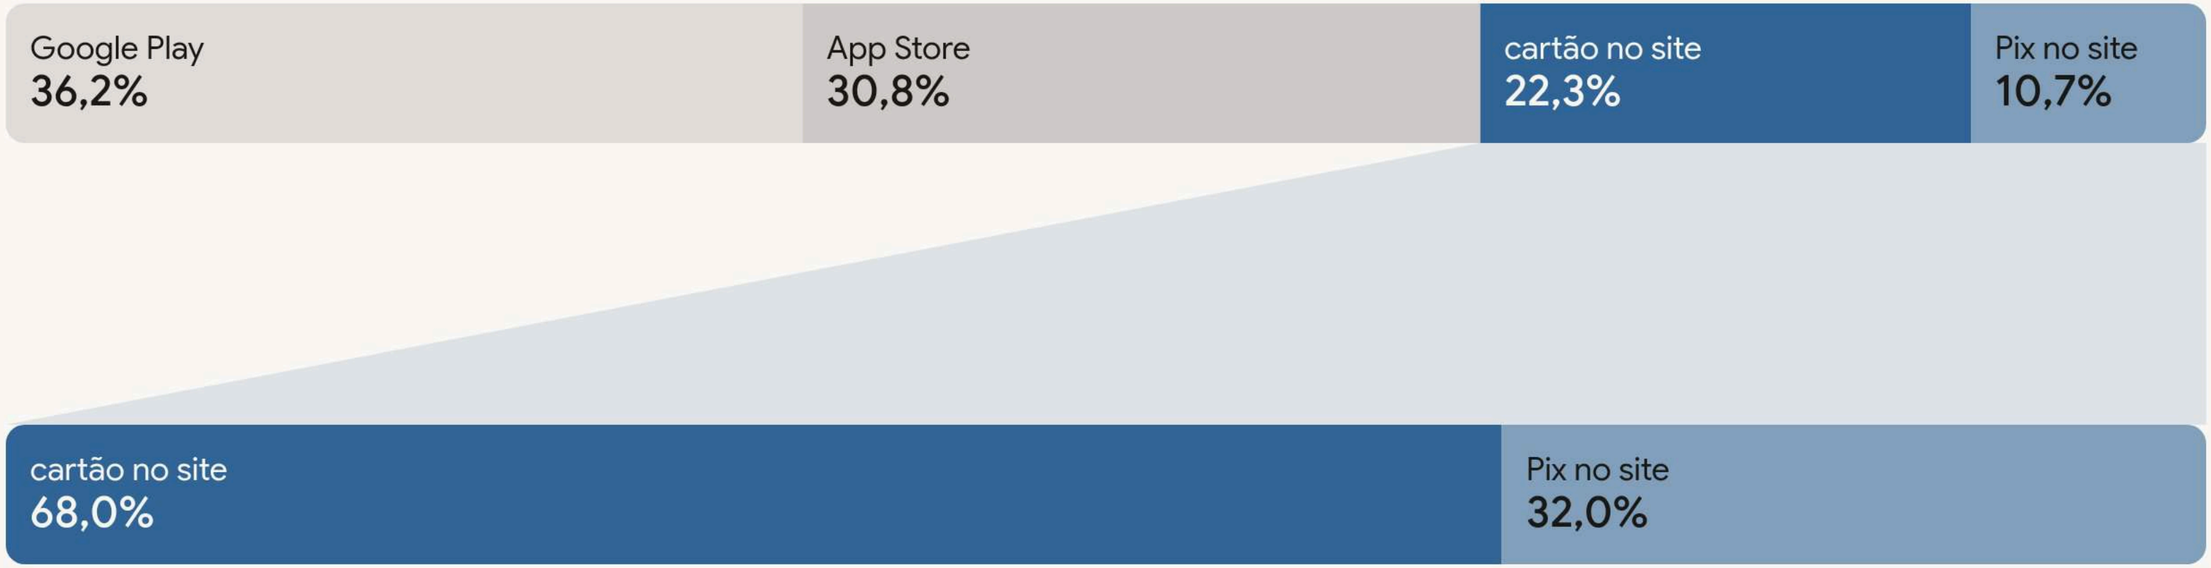
média de minutos por conta

de 60,2 a 109,5 min em 20 sorteios

Amostra que não foi sorteada engana

Quem cancelou de junho a setembro de 2026 e quem respondeu à pesquisa de saída, por canal de cobrança.

Fins de assinatura de junho a setembro de 2026: 3.389



Respostas da pesquisa de saída: 641 contas

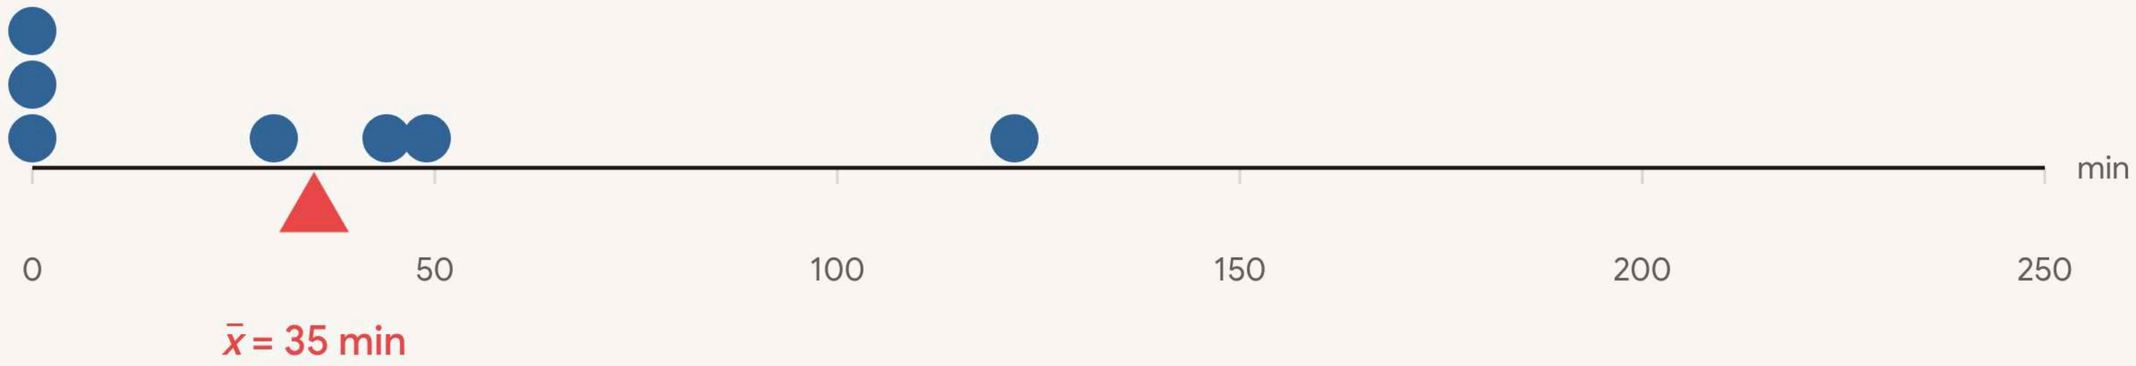
As lojas são 67% dos fins e nenhuma resposta veio delas.

A média é o ponto de equilíbrio

Minutos de treino de uma conta em sete dias de setembro de 2026.

seg 7	ter 8	qua 9	qui 10	sex 11	sáb 12	dom 13
122	30	44	49	0	0	0

$$\bar{x} = \frac{\Sigma x_i}{n} = \frac{245}{7} = 35$$



O extremo puxa a média; a mediana fica

A mesma semana, em ordem; o dia mais longo esticado para 240 minutos.

sex 11	sáb 12	dom 13	ter 8	qua 9	qui 10	seg 7
0	0	0	30	44	49	240
	moda		mediana			

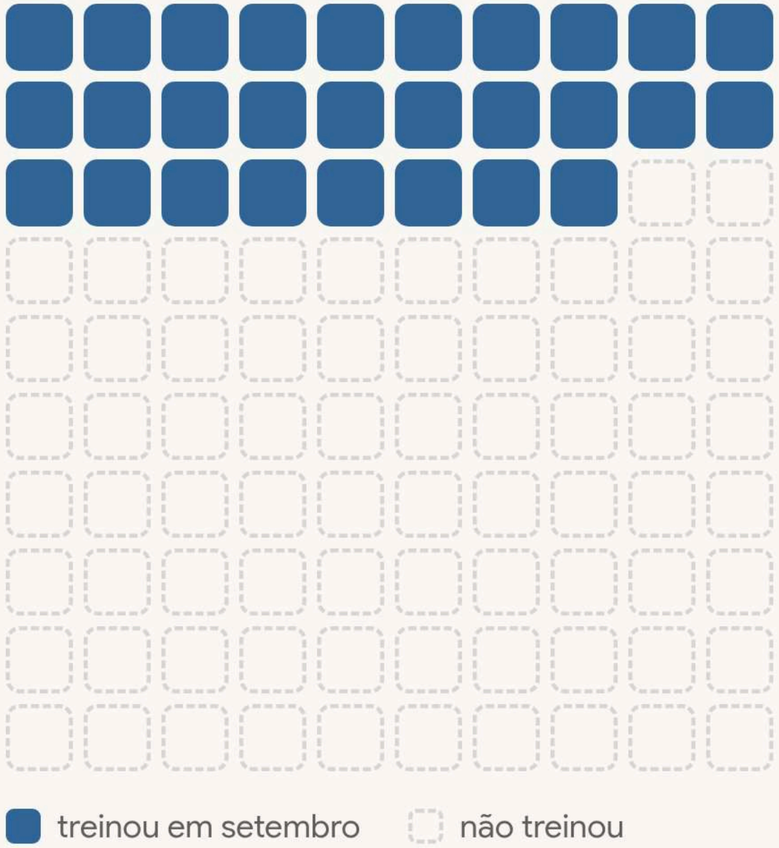
$$\bar{x} = \frac{\Sigma x_i}{n} = \frac{245}{7} = 35$$

média	35 → 51,9
mediana	30 → 30
moda	0 → 0



Média de 83 minutos, mediana zero

Minutos de treino por conta em setembro de 2026, em uso_mensal.csv.



treinou em setembro não treinou

72%

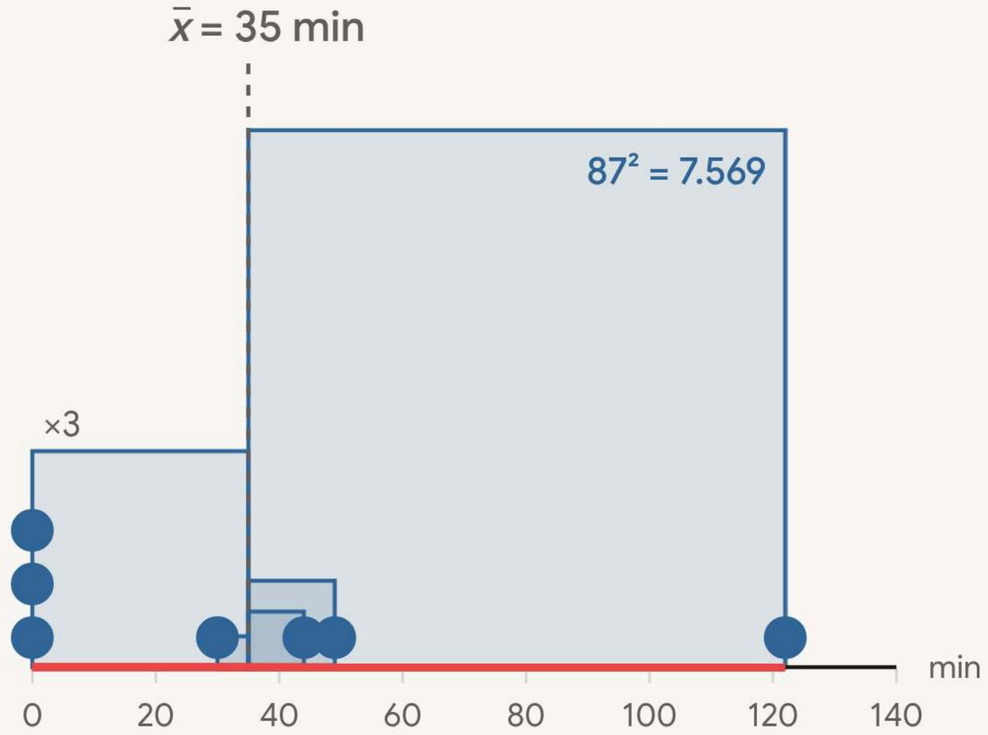
das contas não treinaram

mediana	moda	média
0 min	0 min	83 min

A média sozinha descreve uma conta que quase não existe.

O desvio padrão é a distância típica até a média

Cada desvio em relação à média vira um quadrado.



122	− 35 =	87 →	7.569
30	− 35 =	−5 →	25
44	− 35 =	9 →	81
49	− 35 =	14 →	196
0	− 35 =	−35 →	1.225
0	− 35 =	−35 →	1.225
0	− 35 =	−35 →	1.225

Σ = 11.546

$$s = \sqrt{\frac{\Sigma(x_i - \bar{x})^2}{n - 1}}$$

$$= \sqrt{\frac{11.546}{6}} = 43{,}9 \text{ min}$$

Mesmo desvio padrão, variação relativa diferente

Treinos de janeiro a setembro de 2026, em atividades.parquet.

Duração do treino

média 46,4 min · desvio padrão 23,8 min



CV = 51%

Frequência cardíaca média

média 130,3 bpm · desvio padrão 22,3 bpm



CV = 17%

O CV divide o desvio pela média: compara variáveis em escalas diferentes.

$$CV = \frac{s}{\bar{x}}$$

Os cinco números, pedidos ao agente

Minutos de treino por conta em setembro de 2026, em uso_mensal.csv.

OBJETIVO

Descrever os minutos por conta com centro e dispersão e achar a medida da conta típica.

PROMPT

```
Leia docs/dicionario_dados.md.
Mostre o plano antes de rodar.
Em dados/brutos/uso_mensal.csv, só mes = 2026-09:
1. conte as linhas e os user_id únicos;
2. para minutos, calcule média, mediana, moda, desvio padrão e
coeficiente de variação, dizendo se dividiu por n ou por n - 1;
3. calcule a proporção de contas com zero;
4. diga em duas frases qual medida descreve a conta típica e
por quê.
Não altere nada em dados/brutos/.
```

CONFIRA

- 56.565 linhas, uma por conta.
- Média 82,6 min; mediana 0; moda 0; 72,3% das contas com zero.
- Desvio padrão 221,3 min e CV de 268%: o desvio é maior que a média.
- Armadilha: se a conta típica treina 83 minutos, a resposta leu só a média.

Toda taxa precisa do denominador certo

Frequência, proporção e o churn mensal.

Frequência

$$n$$

por categoria

→

Proporção

$$\frac{n}{total}$$

→

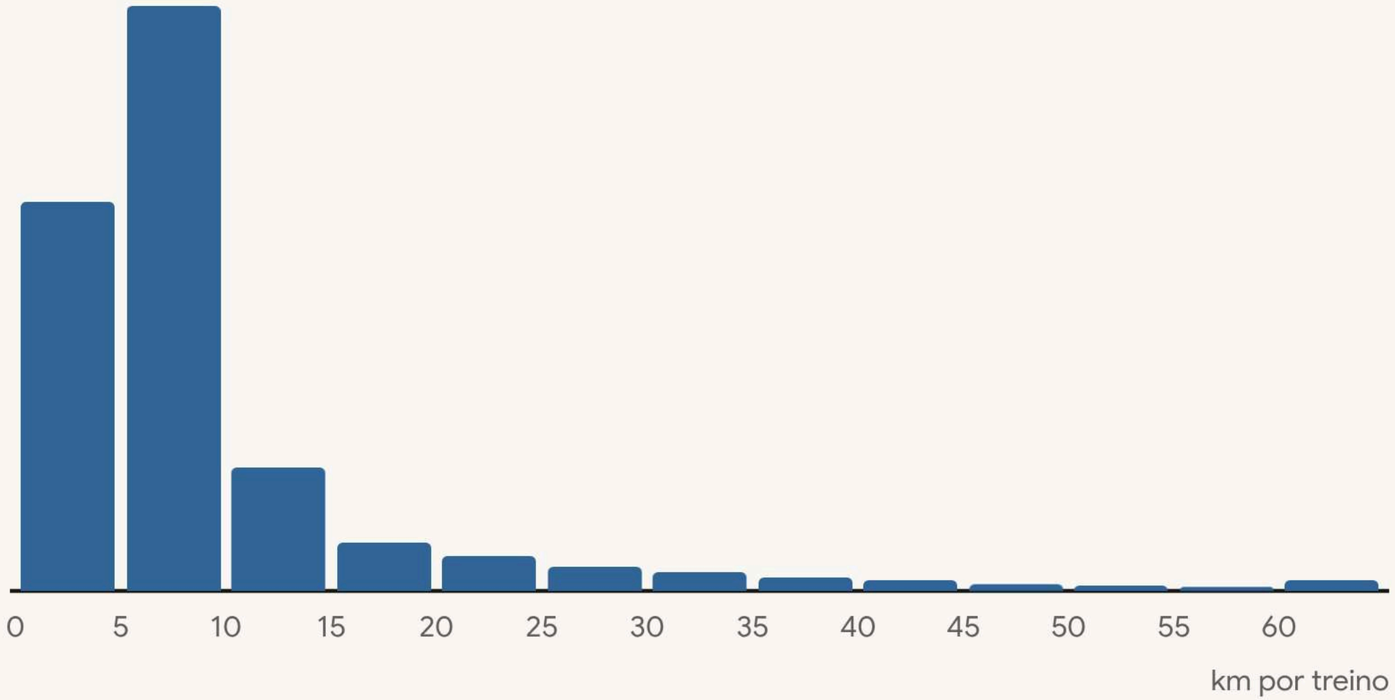
Churn mensal

$$\frac{\text{perdas no mês}}{\text{ativos no início do mês}}$$

A tabela de frequências vira histograma

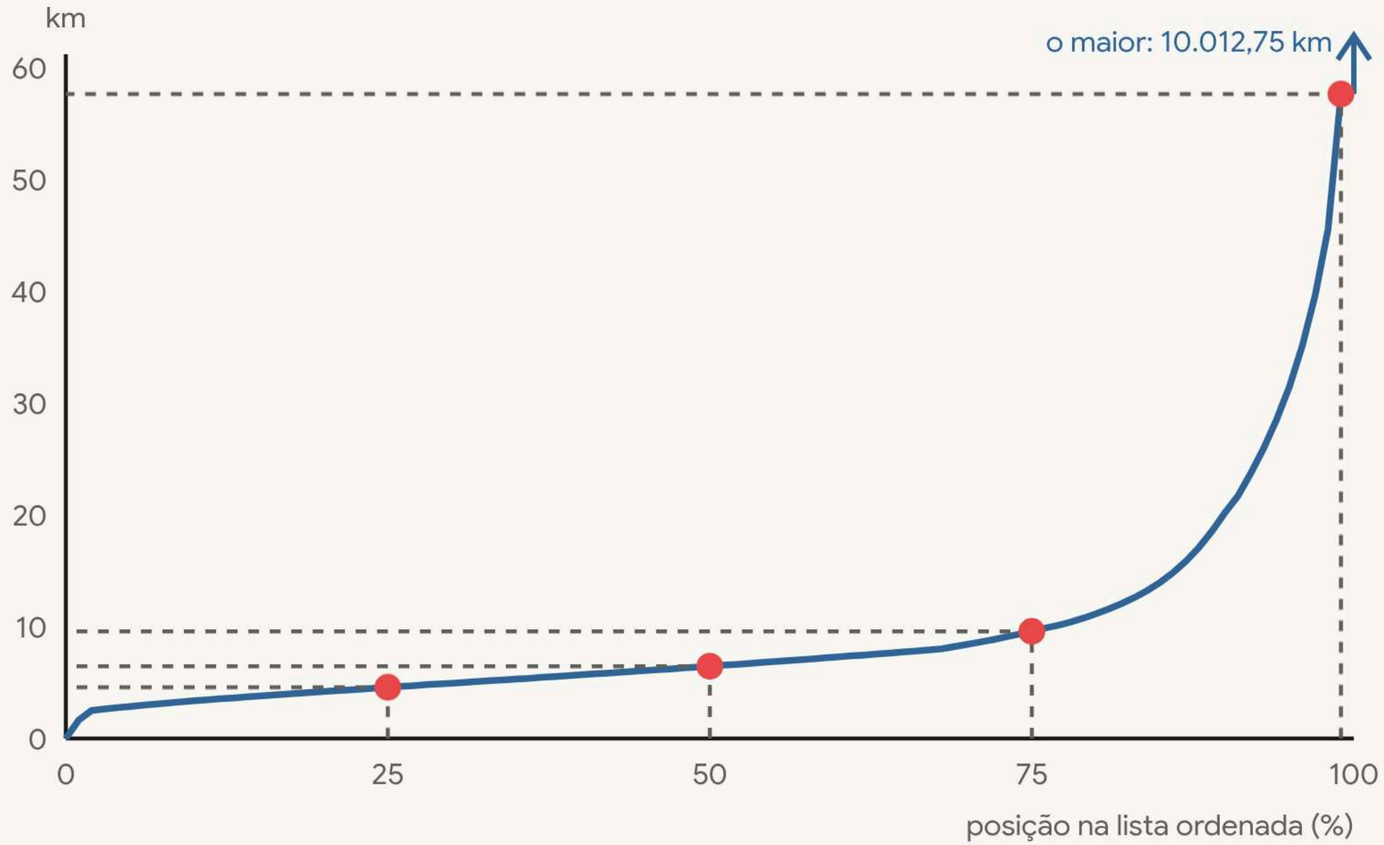
Distância dos 679.640 treinos com GPS, de janeiro a setembro de 2026.

km	treinos	%
0 a 5	207.759	30,6
5 a 10	311.836	45,9
10 a 15	65.775	9,7
15 a 20	25.485	3,7
20 a 25	18.334	2,7
25 a 30	13.214	1,9
30 a 35	9.853	1,4
35 a 40	7.413	1,1
40 a 45	5.861	0,9
45 a 50	3.695	0,5
50 a 55	2.609	0,4
55 a 60	1.838	0,3
60 ou mais	5.968	0,9



Percentil é posição na lista ordenada

Os 679.640 treinos em ordem crescente de distância.



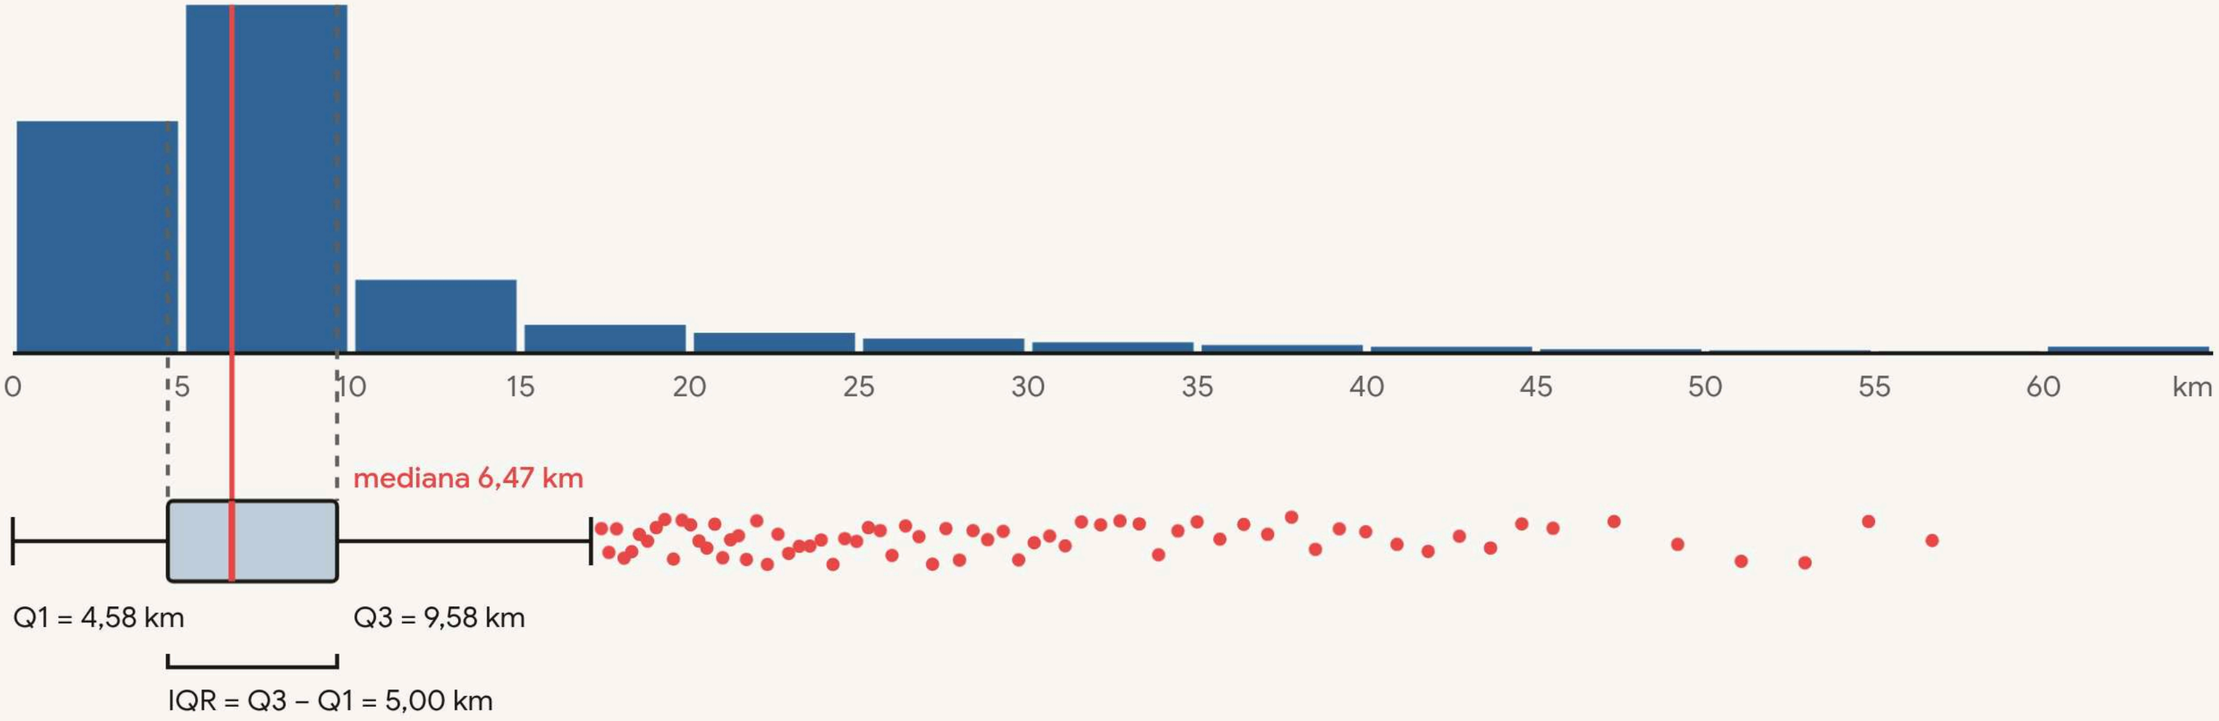
$$\text{posição} = p \times (n - 1) + 1$$

n = 679.640 treinos

	posição	km
p25 · Q1	169.910,75	4,58
p50 · mediana	339.820,50	6,47
p75 · Q3	509.730,25	9,58
p99	672.843,61	57,64

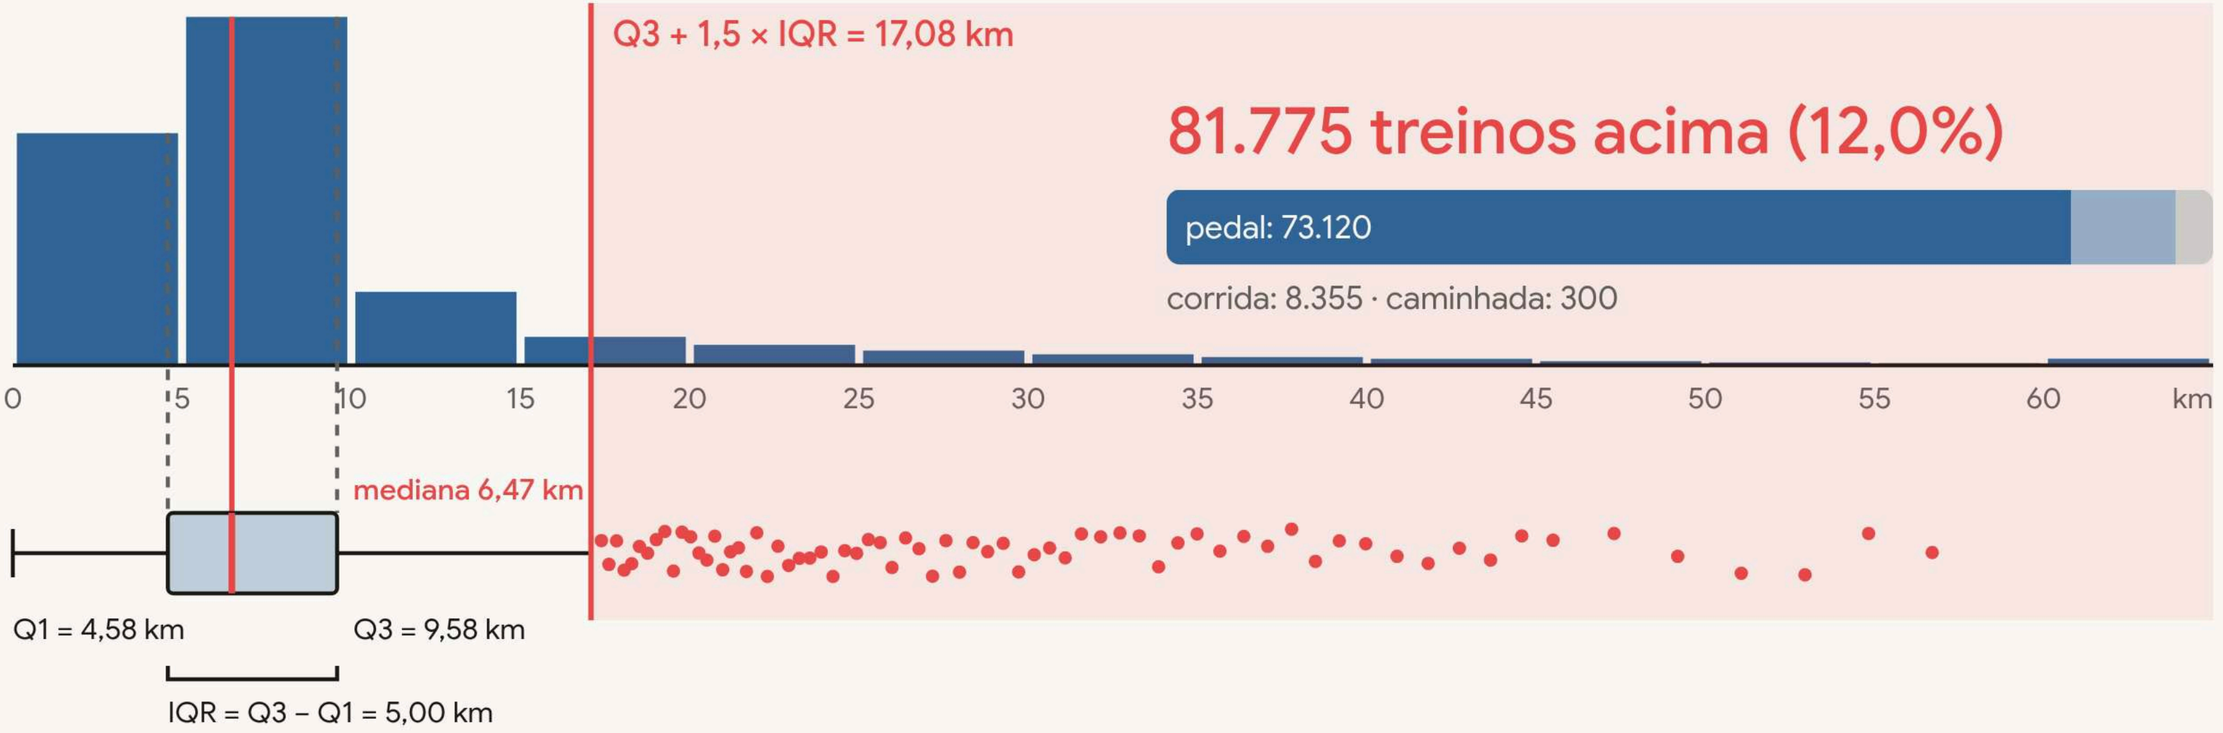
O boxplot nasce do histograma

Quartis, intervalo interquartil e os treinos além do limite.



A regra marca; o grupo decide

Quase todos os treinos acima do limite são de pedal.



$$z = \frac{x - \bar{x}}{s}$$

|z| > 3: 956 treinos

acima de 191,6 km

ANÁLISE EXPLORATÓRIA · DISTRIBUIÇÕES

Frequências | Quartis e extremos | Formas

Histograma, quartis e extremos, pedidos ao agente

Distância dos 679.640 treinos com GPS, em atividades.parquet.

OBJETIVO

Ver a forma da distância dos treinos e marcar os extremos por duas regras, sem apagar nada.

PROMPT

```
Leia docs/dicionario_dados.md.
Mostre o plano antes de rodar.
Em dados/brutos/atividades.parquet, só treinos com distancia_km
preenchida:
1. conte os treinos;
2. faça a tabela de frequências e o histograma em classes de
5 km, a última com 60 km ou mais;
3. calcule Q1, mediana, Q3 e IQR;
4. marque os extremos pela regra Q3 + 1,5 × IQR e por |z| > 3,
com a contagem por tipo em cada regra.
Não remova nada nem altere dados/brutos/.
```

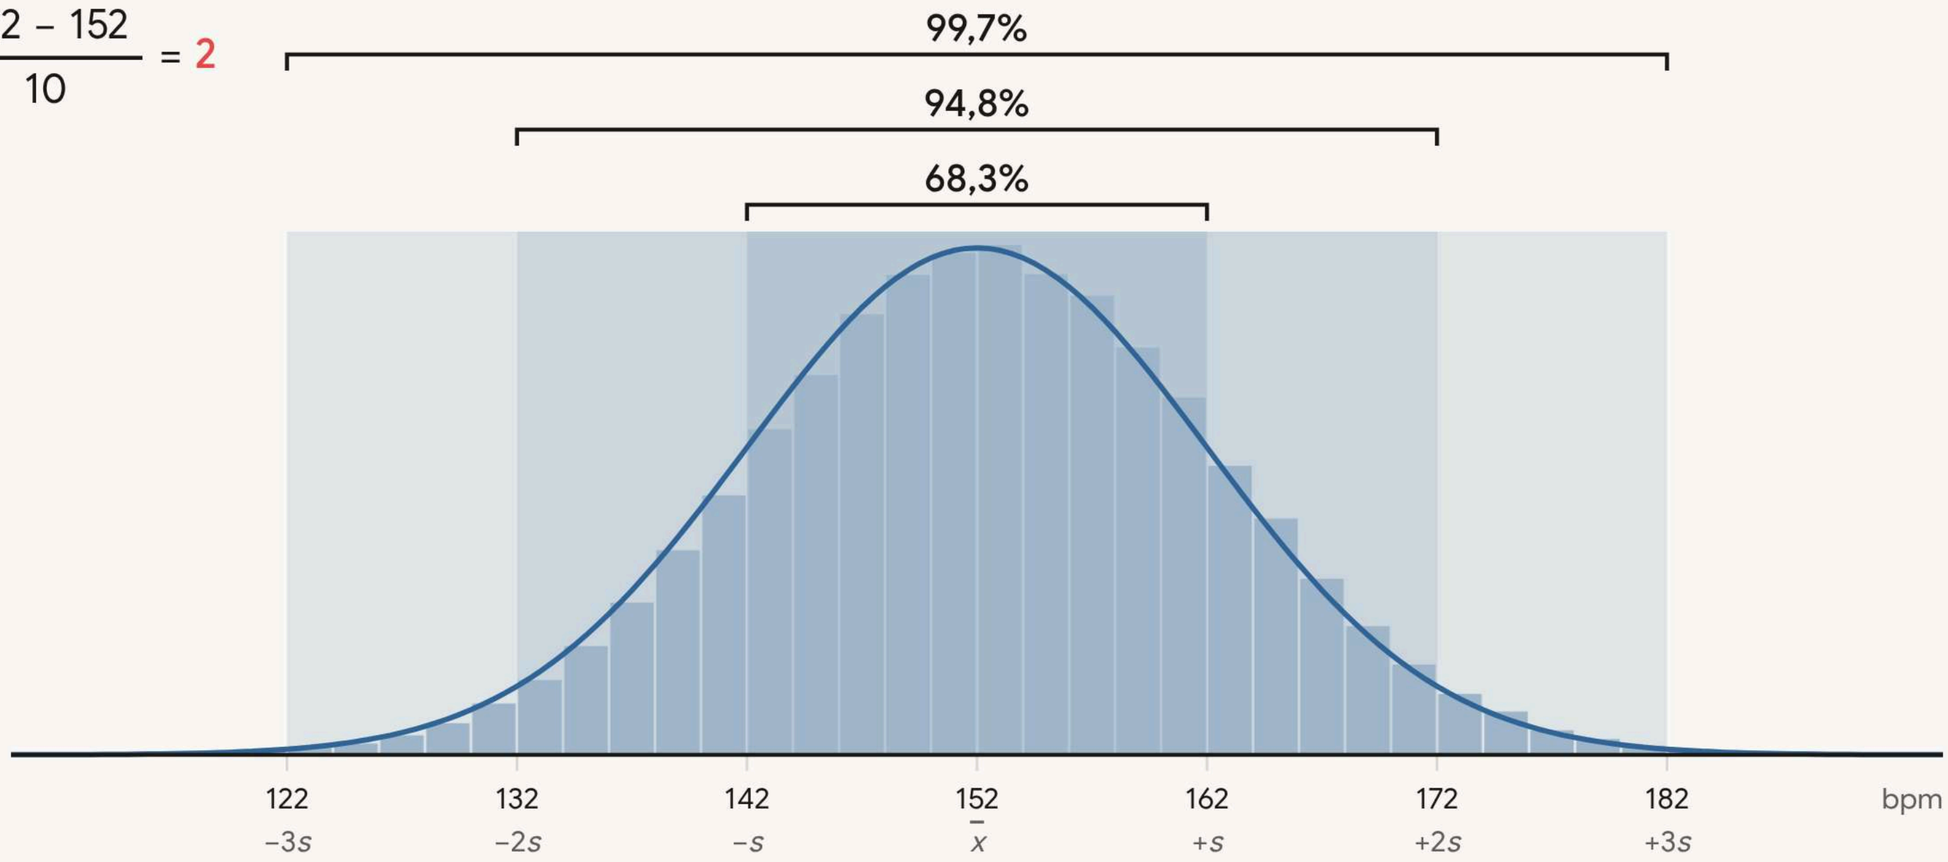
CONFIRA

- 679.640 treinos; 45,9% entre 5 e 10 km.
- Q1 4,58 km; mediana 6,47; Q3 9,58; IQR 5,00.
- 1,5 × IQR: 81.775 treinos acima de 17,08 km, 73.120 de pedal (com ride).
- |z| > 3: 956 acima de 191,6 km. A regra marca; o grupo decide.

Na curva normal, 68, 95 e 99,7

Frequência cardíaca média de 149.377 corridas: média 152 bpm, desvio padrão 10 bpm.

$$z = \frac{172 - 152}{10} = 2$$

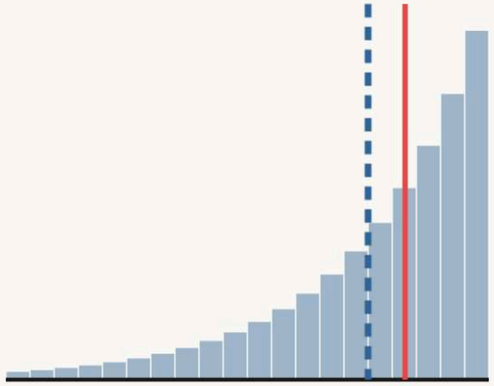


A média vai para o lado da cauda

Média e mediana em quatro distribuições; três são da base de setembro de 2026.

À esquerda

ilustração

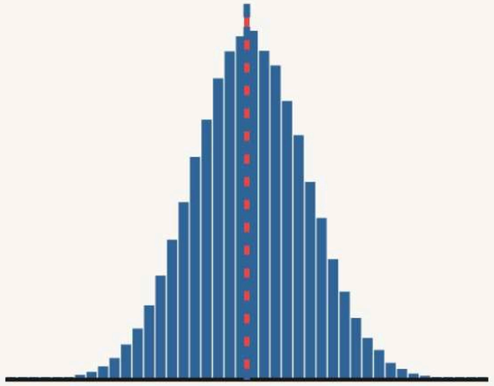


média < mediana

cauda para os valores baixos

Simétrica

frequência cardíaca, corridas

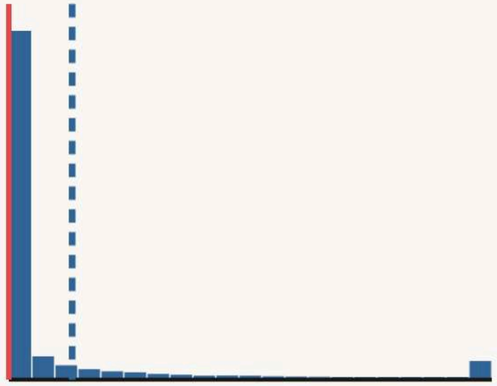


média = mediana

média 152, mediana 152 bpm

À direita

minutos por conta

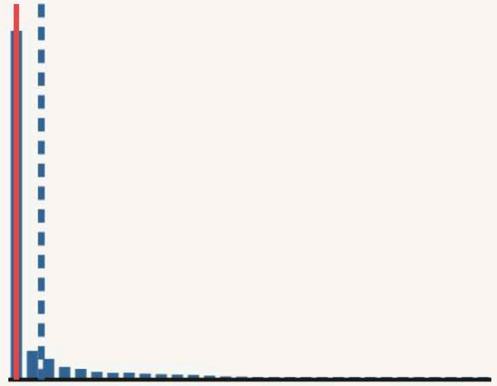


média > mediana

média 83, mediana 0 min

Contagem

dias ativos no mês



só valores inteiros

média 1,5, mediana 0 dia

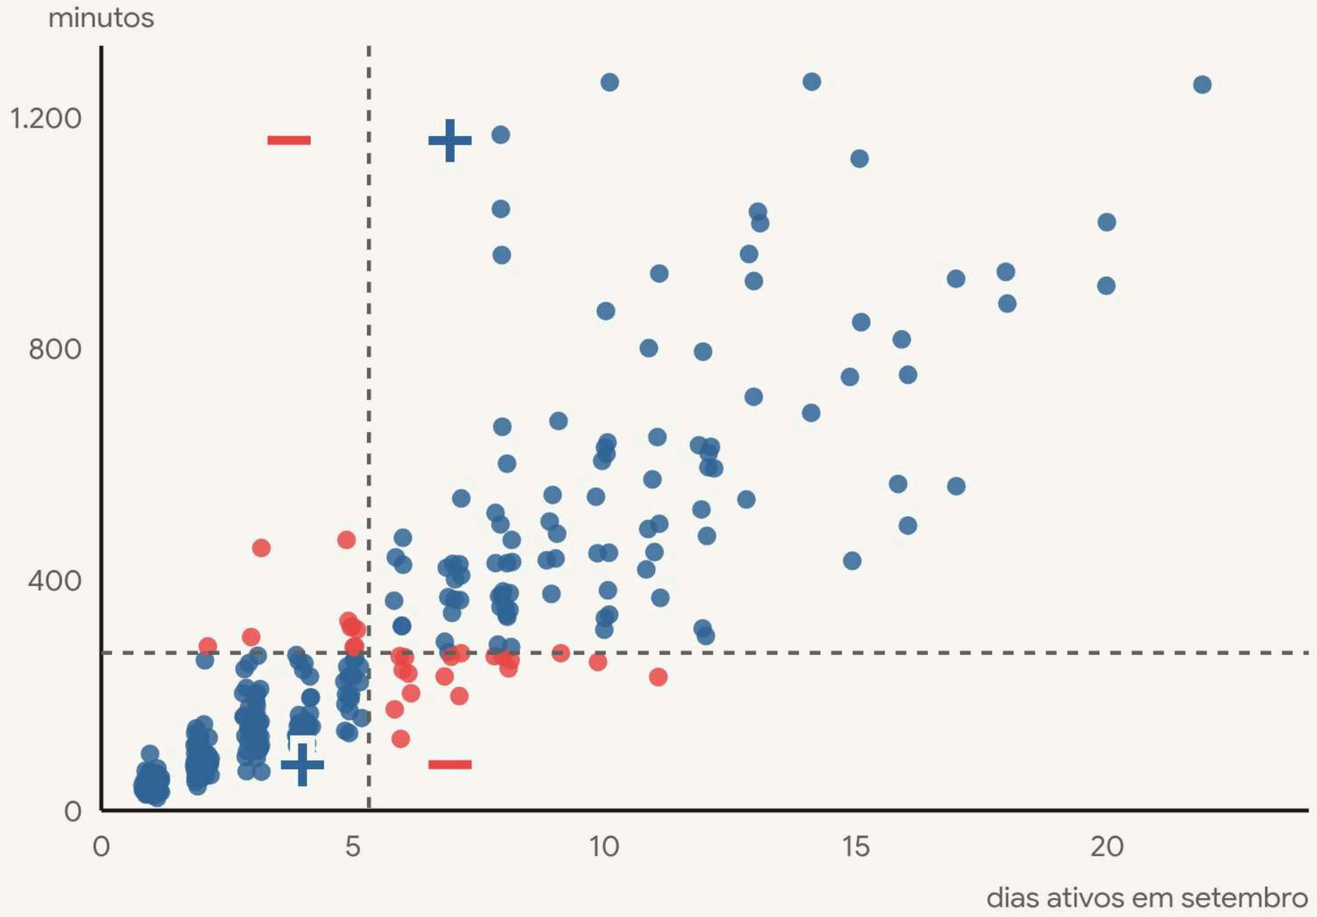
média | mediana

ANÁLISE EXPLORATÓRIA · CORRELAÇÃO

Medir | Ler | Causa

Mais dias ativos, mais minutos

Dias ativos e minutos de treino por conta em setembro de 2026; 320 contas sorteadas no gráfico.



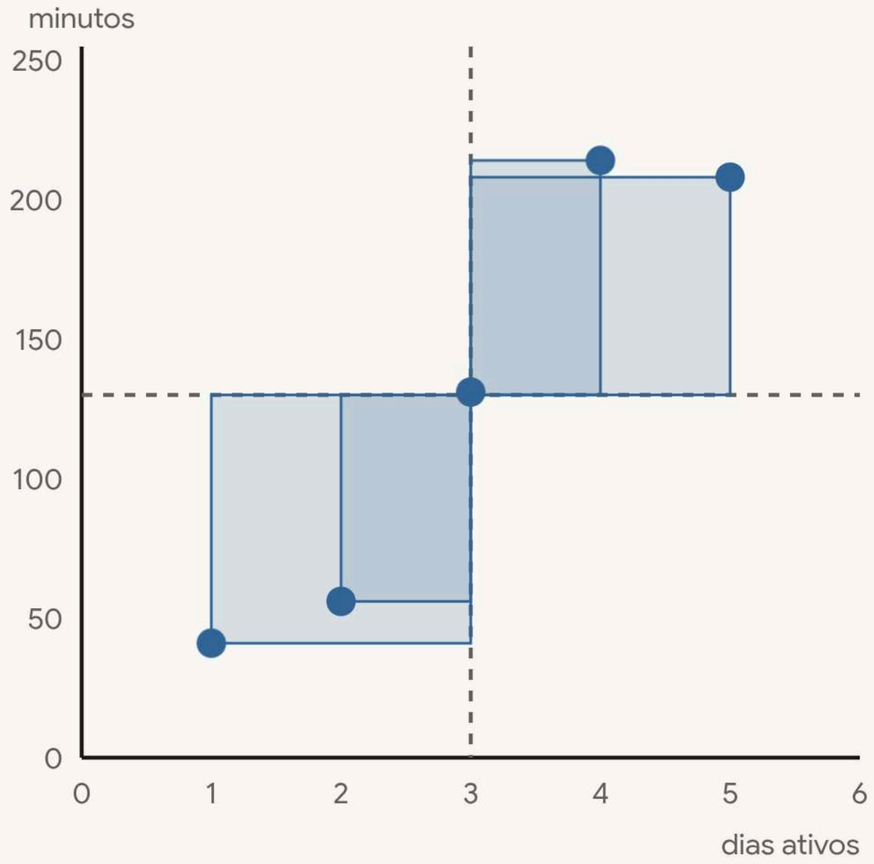
$r = 0{,}86$

15.685 contas que treinaram em setembro de 2026

No gráfico, 292 de 320 contas estão nos quadrantes +: acima das duas médias ou abaixo das duas.

O r soma os produtos dos desvios

Cinco contas reais de setembro de 2026.



x	y	$x-\bar{x}$	$y-\bar{y}$	$(x-\bar{x})(y-\bar{y})$	$(x-\bar{x})^2$	$(y-\bar{y})^2$
1	41	−2	−89	178	4	7.921
2	56	−1	−74	74	1	5.476
3	131	0	1	0	0	1
4	214	1	84	84	1	7.056
5	208	2	78	156	4	6.084
Σ				492	10	26.538

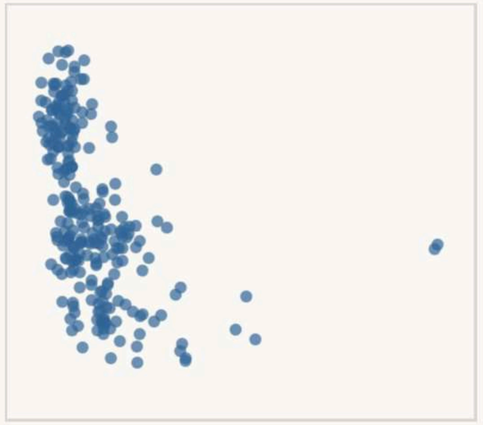
$$r = \frac{\Sigma(x-\bar{x})(y-\bar{y})}{\sqrt{\Sigma(x-\bar{x})^2 \cdot \Sigma(y-\bar{y})^2}}$$

$$= \frac{492}{\sqrt{10 \times 26.538}} = 0{,}955$$

O r vai de –1 a 1 e só vê reta

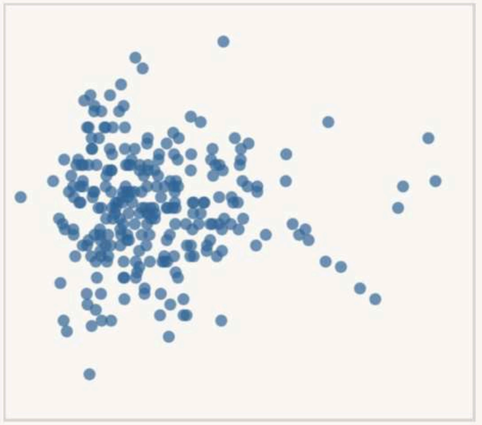
Quatro pares de variáveis dos treinos de 2026; 260 treinos sorteados em cada gráfico.





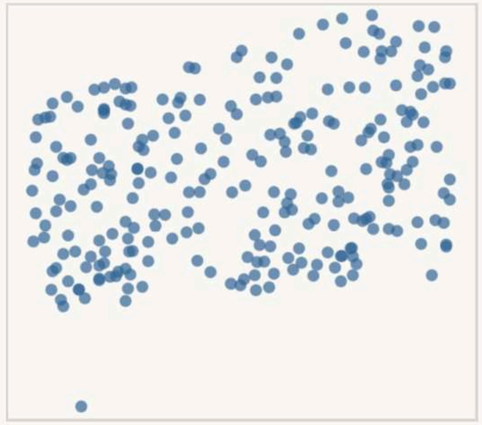
corrida: km × ritmo

r = –0,48



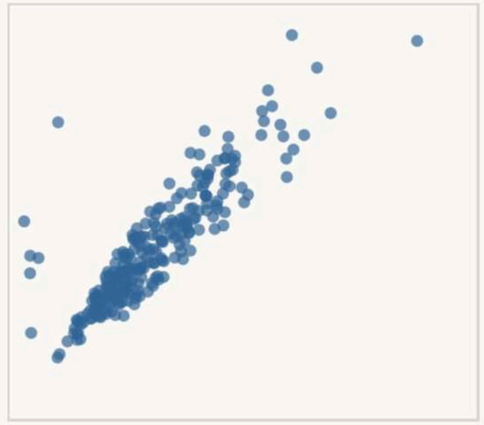
corrida: km × batimentos

r = 0,00



caminhada: ritmo × minutos

r = 0,28



corrida: km × minutos

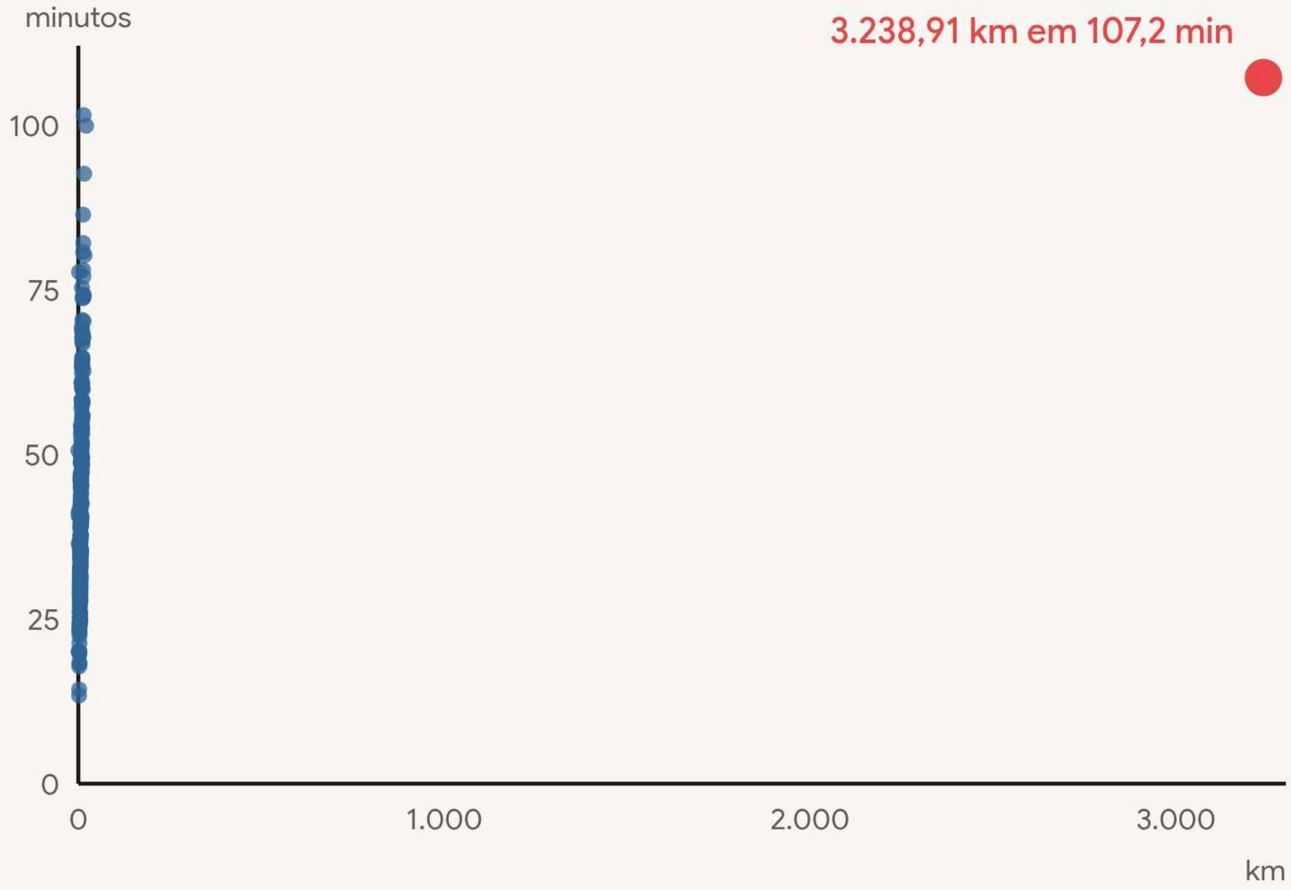
r = 0,88

ANÁLISE EXPLORATÓRIA · CORRELAÇÃO

Medir | Ler | Causa

Um punhado de erros derruba o r

Corridas: distância e duração, sem e com os treinos impossíveis.



$r = 0,12$

Com os 555 treinos de corrida acima de 200 km, o r da base cai de 0,88 para 0,12.

Correlação não é causa

Manchetes que viraram notícia e o que estava por trás.

1 **Países que comem mais chocolate ganham mais Nobel**
MESSERLI, 2012 — terceira variável

2 **Criança que resiste ao marshmallow vai melhor na escola**
WATTS; DUNCAN; QUAN, 2018 — terceira variável

3 **Uma taça por dia faz viver mais**
STOCKWELL et al., 2016 — seleção

4 **Fumante pega menos covid**
GRIFFITH et al., 2020 — seleção

5 **Refrigerante diet triplica o risco de AVC e demência**
PASE et al., 2017; WERSCHING; GARDENER; SACCO, 2017 — causalidade reversa

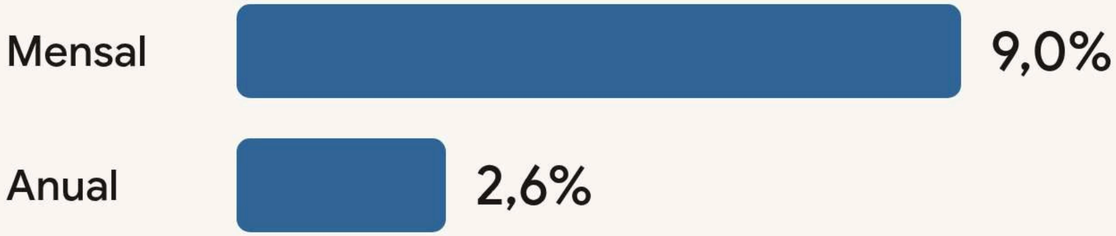
6 **As buscas no Google preveem a gripe**
LAZER et al., 2014 — coincidência

ANÁLISE EXPLORATÓRIA · CORRELAÇÃO

Medir | Ler | Causa

O cruzamento aponta suspeitos, não prova causa

Perda mensal média em 2025, por plano.



plano anual → ? → assinante fica

Números da aula 1, série mensal de 2025.

comparação

O anual só pode sair no aniversário; o mensal pode sair todo mês.

seleção

Quem escolhe o anual pode já ser quem pretendia ficar.

terceira variável

Preço, canal e cupom mudam junto com o plano.

ANÁLISE EXPLORATÓRIA · CORRELAÇÃO

Medir | Ler | Causa

A correlação sobrevive a uma terceira variável?

Sessões no app e minutos de treino em setembro de 2026, com as atividades como terceira variável.

OBJETIVO

Validar se quem abre mais o app treina mais minutos ou se os dois só seguem o número de treinos.

PROMPT

```
Leia dicionario_dados.md e me mostre o plano antes de rodar.
Em uso_mensal.csv, só mes = 2026-09 e dias_ativos > 0:
1. conte linhas e contas (user_id únicos);
2. calcule o r de Pearson entre sessoes_app e minutos;
3. calcule o mesmo r dentro de cada valor de atividades e a
média ponderada pelo número de contas;
4. calcule o r parcial de sessoes_app e minutos controlando
atividades.
Mostre as contagens de cada passo. Não altere nada em
dados/brutos/.
```

CONFIRA

- 15.685 contas com treino em setembro de 2026, de 56.565 linhas no mês.
- r de sessões e minutos: 0,88 (0,92 com quem não treinou).
- Por número de atividades e no r parcial, cai para 0,02: não sobrevive.
- Armadilha: faixas largas de atividades deixam a terceira variável vazar (r de 0,36 a 0,67).

ANÁLISE EXPLORATÓRIA · RETRATO E HISTÓRICO

A situação numa data se reconstrói pelos eventos

Em teste, pagando, com a renovação ligada ou desligada, em qualquer dia do passado.



EVENTOS_ASSINATURA.CSV · UM ASSINANTE

O retrato de 01/10 não descreve 31/07

Usar o retrato de 01/10 para descrever 31/07 põe no passado o que ainda não tinha acontecido.



EVENTOS_ASSINATURA.CSV · UM ASSINANTE

KAUFMAN et al. (2012)

ANÁLISE EXPLORATÓRIA · RETRATO E HISTÓRICO

Pelos eventos, 823 respostas mudam

Os 2.250 assinantes que o retrato de 01/10 mostra com a renovação desligada, vistos em 31/07.

OBJETIVO

Reconstruir pelos eventos a situação da renovação em 31/07 e medir o erro de usar o retrato de 01/10.

PROMPT

```
Leia docs/dicionario_dados.md.
Mostre o plano antes de rodar e diga como vai tratar o fuso.
1. Em dados/brutos/assinaturas.csv, separe as ativas com
renovacao_automatica = nao, sem as contas de teste (e-mail
@vitaliza.com.br em usuarios.csv), e conte;
2. para cada uma, reconstrua por eventos_assinatura.csv a
situação em 31/07/2026: ainda não assinava, renovação ligada ou
desligada;
3. mostre a contagem de cada situação.
Não altere nada em dados/brutos/.
```

CONFIRA

- 2.250 assinantes no retrato com a renovação desligada.
- Em 31/07: 1.427 já com a renovação desligada, 754 com ela ligada e 69 que ainda não assinavam.
- O retrato erraria 823 (37%): é o tamanho do vazamento.
- Armadilha: assinatura anterior a 01/07/2024 não tem evento de início; sem desligamento até 31/07, a renovação estava ligada.

ANÁLISE EXPLORATÓRIA · DA HIPÓTESE AO CRUZAMENTO

Da afirmação à tabela

Uma hipótese da terça com o Fábio vira uma pergunta, uma taxa por grupo e uma comparação.

1

Hipótese

uma afirmação da terça com o Fábio

→

2

Pergunta

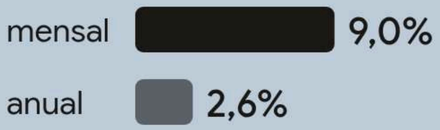
A perda é igual nos dois planos?

→

3

Taxa por grupo

perda mensal média em 2025



→

4

Comparação

9,0%
no mensal

contra

2,6%
no anual

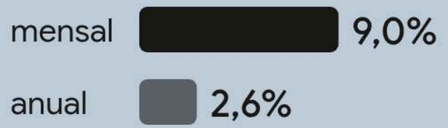
Cruzamento aponta suspeitos e não prova causa

Três cuidados antes de acreditar numa diferença.

3

Taxa por grupo

perda mensal média em 2025



1. **Comparar coisas comparáveis**
   O anual só sai no aniversário.

2. **Olhar o tamanho de cada grupo**

3. **Desconfiar de diferenças que somem quando se abre por outra variável**

3

Na prática

Quatro missões, três funções, um registro



NA PRÁTICA

A pergunta

30 minutos, em grupo, com o agente do grupo

Entre quem pagava em 30/06/2026, quem saiu até 30/09 se comportava diferente de quem ficou? Quais duas características mais separam os dois grupos, e por que cada uma pode ser só correlação?

BASE

Quem pagava a assinatura em 30/06/2026

SAIU

A assinatura terminou entre 01/07 e 30/09/2026

FICOU

Seguia assinante em 30/09/2026

CANDIDATAS

- uso
- plano
- canal de cobrança
- tempo de casa
- aquisição
- onboarding
- suporte

NA PRÁTICA

O que entregar no fim

O mínimo; a técnica é do grupo, sempre justificada



Uma tabela

Os dois grupos lado a lado: tamanho, taxa de saída e o centro e a dispersão de cada característica



Um gráfico

A distribuição da característica que mais separa, nos dois grupos



Três frases

O que o dado diz, o que ele não diz e a próxima pergunta, cada uma com um número

- E o `decisoes.md`, com cada decisão do caminho e o efeito na contagem

NA PRÁTICA

Três funções

Uma tela por grupo, um papel por pessoa

Piloto

Escreve os pedidos ao agente e aprova o plano antes de rodar

Auditor

Confere as contagens de cada etapa e três assinantes à mão

Relator

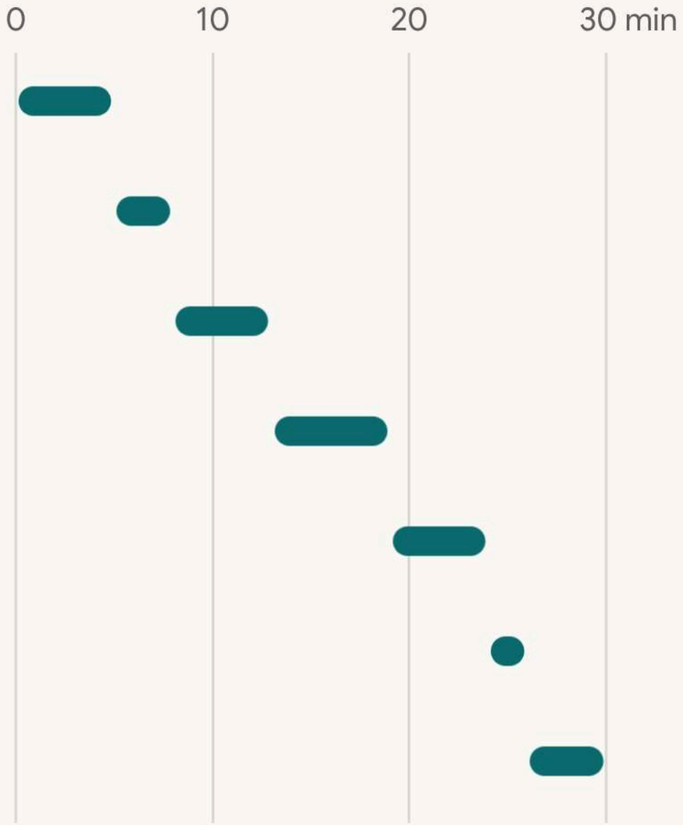
Registra cada decisão no decisoes.md e escreve as três frases

NA PRÁTICA

Sete passos em 30 minutos

O roteiro tem um prompt pronto para cada passo

1	Definir os grupos	5 min	Pelos eventos: quem pagava em 30/06 e quem saiu até 30/09
2	Conferir a qualidade	3 min	Só os arquivos que a pergunta usa, pelas cinco dimensões
3	Uma linha por assinante	5 min	Tudo medido antes de 01/07, sem multiplicar linhas
4	Comparar os grupos	6 min	Mediana, quartis, distribuição e taxa por categoria
5	Testar uma terceira variável	5 min	A diferença se mantém quando se abre pelo plano?
6	Registrar as decisões	2 min	Cada escolha no decisoes.md, com o efeito na contagem
7	Escrever as três frases	4 min	O que o dado diz, o que não diz e a próxima pergunta



NA PRÁTICA

Passo 1: definir os grupos

Objetivo, prompt e o que conferir

1	Definir os grupos	5 min
2	Conferir a qualidade	3 min
3	Uma linha por assinante	5 min
4	Comparar os grupos	6 min
5	Testar uma terceira variável	5 min
6	Registrar as decisões	2 min
7	Escrever as três frases	4 min

OBJETIVO

Separar quem saiu de quem ficou pela data dos eventos

PROMPT

```
Leia o AGENTS.md. Não altere nada em dados/brutos/.
Use dados/brutos/eventos_assinatura.csv, com os horários em Z
(UTC) convertidos para Brasília, e marque cada user_id:
base = pagava em 30/06/2026 (evento com plano preenchido até
30/06 e nenhum fim até 30/06);
saiu = da base, teve assinatura_expirada, reembolso ou
chargeback de 01/07 a 30/09/2026; ficou = o resto da base.
Mostre o plano antes de rodar e, depois, as contagens de cada
etapa. Salve dados/processados/grupos.csv (user_id, saiu).
```

CONFIRA

Saiu mais ficou dá a base. A taxa fica perto de três meses de churn do LEIA-ME. Três user_id conferidos à mão no arquivo.

NA PRÁTICA

Passo 5: a terceira variável

Objetivo, prompt e o que conferir

1	Definir os grupos	5 min
2	Conferir a qualidade	3 min
3	Uma linha por assinante	5 min
4	Comparar os grupos	6 min
5	**Testar uma terceira variável**	5 min
6	Registrar as decisões	2 min
7	Escrever as três frases	4 min

OBJETIVO

Ver se a diferença sobrevive a uma terceira variável

PROMPT

```
Use dados/processados/assinantes.csv. Não altere nada em
dados/brutos/.
Pegue as duas características que mais separaram quem saiu de
quem ficou e abra cada uma por uma terceira variável: o plano
(mensal e anual) ou, se for o próprio plano, o mês de
aniversário da assinatura. Mostre a taxa de saída e o tamanho
de cada subgrupo. A diferença se mantém, diminui, some ou
inverte?
Para quem saiu, mostre quando foi o
renovacao_automatica_desligada em relação a abril a junho de
2026.
Mostre o plano antes de rodar.
```

CONFIRA

Subgrupo quase sem saídas: ele podia sair no período? A renovação foi desligada antes ou depois do uso medido?

NA PRÁTICA

Quem saiu se comportava diferente?

Entrega: uma tabela, um gráfico e três frases

1	Definir os grupos	5 min
2	Conferir a qualidade	3 min
3	Uma linha por assinante	5 min
4	Comparar os grupos	6 min
5	Testar uma terceira variável	5 min
6	Registrar as decisões	2 min
7	Escrever as três frases	4 min



FECHAMENTO · AULA 2

O que levar da aula 2

Cinco ideias da aula de hoje

A pasta e o arquivo de contexto são o primeiro artefato do grupo — O AMBIENTE
o bruto nunca é editado; as regras do case num arquivo que o agente lê

O agente executa e o grupo confere — O AMBIENTE
ler o código, rodar de novo e checar três números à mão

Limpar é decidir e registrar — ANÁLISE EXPLORATÓRIA
corrigir, remover ou marcar, com o motivo e o efeito em decisoes.md

Média sem distribuição engana — ANÁLISE EXPLORATÓRIA
setembro de 2026: média de 83 minutos de treino por conta, mediana zero

Cruzamento aponta suspeitos — ANÁLISE EXPLORATÓRIA
e não prova causa

FECHAMENTO · AULA 2

Aula 3, 29/10: clusterização

Trazer a base integrada no corte e o decisoes.md

HOJE · 22/10 · AULA 2

A análise exploratória

a base da entrega de 13/11

29/10 · AULA 3

Clusterização

leitura prévia da aula 3

inteli | inteli MBA

Cesar Almiñana

cesar@prof.inteli.edu.br

cesar@almn.ai

WhatsApp
+55 11 999 018 180

LinkedIn
linkedin.com/in/ccalminana

REFERÊNCIAS · AULA 2

Cada conceito e cada fato citado tem fonte

As 16 obras e páginas que sustentam as telas, em ordem alfabética (ABNT NBR 6023:2018)

Obras de A a L	Na aula
ANTHROPIC. **Advanced setup**. Claude Code Docs, [2026]. Disponível em: https://code.claude.com/docs/en/setup. Acesso em: 17 out. 2026.	**Instalação do Claude Code** Montando o ambiente
GRIFFITH, Gareth J. *et al*. Collider bias undermines our understanding of COVID-19 disease risk and severity. **Nature Communications**, v. 11, art. 5749, 12 nov. 2020. DOI: https://doi.org/10.1038/s41467-020-19478-2.	**Fumante e covid** Correlação
KAUFMAN, Shachar; ROSSET, Saharon; PERLICH, Claudia; STITELMAN, Ori. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, p. 1-21, dez. 2012. DOI: https://doi.org/10.1145/2382577.2382579.	**Vazamento** Retrato e histórico
LAZER, David; KENNEDY, Ryan; KING, Gary; VESPIGNANI, Alessandro. The parable of Google Flu: traps in big data analysis. **Science**, v. 343, n. 6176, p. 1203-1205, 14 mar. 2014. DOI: https://doi.org/10.1126/science.1248506.	**Buscas e gripe** Correlação

REFERÊNCIAS · AULA 2

Cada conceito e cada fato citado tem fonte

As 16 obras e páginas que sustentam as telas, em ordem alfabética (ABNT NBR 6023:2018)

Obras de M a O	Na aula
MCKINNEY, Wes. **Python for data analysis**: data wrangling with pandas, NumPy, and Jupyter. 3. ed. Sebastopol: O'Reilly, 2022. Disponível em: https://wesmckinney.com/book/. Acesso em: 17 out. 2026.	**Limpeza com pandas (cap. 7)** Leitura prévia
MESSERLI, Franz H. Chocolate consumption, cognitive function, and Nobel laureates. **The New England Journal of Medicine**, v. 367, n. 16, p. 1562-1564, 18 out. 2012. DOI: https://doi.org/10.1056/NEJMon1211064.	**Chocolate e Nobel** Correlação
OPENAI. **Codex CLI**. [S. l.], [2026a]. Disponível em: https://learn.chatgpt.com/docs/codex/cli. Acesso em: 17 out. 2026.	**Instalação do Codex** Montando o ambiente
OPENAI. **Codex in ChatGPT**. OpenAI Help Center, [2026b]. Disponível em: https://help.openai.com/en/articles/11369540. Acesso em: 17 out. 2026.	**Planos do Codex** Montando o ambiente

REFERÊNCIAS · AULA 2

Cada conceito e cada fato citado tem fonte

As 16 obras e páginas que sustentam as telas, em ordem alfabética (ABNT NBR 6023:2018)

Obras de P a T	Na aula
PASE, Matthew P. *et al.* Sugar- and artificially sweetened beverages and the risks of incident stroke and dementia: a prospective cohort study. **Stroke**, v. 48, n. 5, p. 1139-1146, maio 2017. DOI: https://doi.org/10.1161/STROKEAHA.116.016027.	**Refrigerante diet e demência** Correlação
REDMAN, Thomas C. Bad data costs the U.S. $3 trillion per year. **Harvard Business Review**, Boston, 22 set. 2016. Disponível em: https://hbr.org/2016/09/bad-data-costs-the-u-s-3-trillion-per-year. Acesso em: 17 out. 2026.	**O custo do dado ruim** Qualidade de dados
STOCKWELL, Tim *et al.* Do "moderate" drinkers have reduced mortality risk? A systematic review and meta-analysis of alcohol consumption and all-cause mortality. **Journal of Studies on Alcohol and Drugs**, v. 77, n. 2, p. 185-198, mar. 2016. DOI: https://doi.org/10.15288/jsad.2016.77.185.	**Uma taça por dia** Correlação
TUKEY, John W. **Exploratory data analysis**. Reading, Mass.: Addison-Wesley, 1977. 688 p.	**Análise exploratória** O que é AED

REFERÊNCIAS · AULA 2

Cada conceito e cada fato citado tem fonte

As 16 obras e páginas que sustentam as telas, em ordem alfabética (ABNT NBR 6023:2018)

Obras de W a W	Na aula
WANG, Richard Y.; STRONG, Diane M. Beyond accuracy: what data quality means to data consumers. **Journal of Management Information Systems**, v. 12, n. 4, p. 5-33, 1996. DOI: https://doi.org/10.1080/07421222.1996.11518099.	**Cinco dimensões** Qualidade de dados
WATTS, Tyler W.; DUNCAN, Greg J.; QUAN, Haonan. Revisiting the marshmallow test: a conceptual replication investigating links between early delay of gratification and later outcomes. **Psychological Science**, v. 29, n. 7, p. 1159-1177, jul. 2018. DOI: https://doi.org/10.1177/0956797618761661.	**Teste do marshmallow** Correlação
WERSCHING, Heike; GARDENER, Hannah; SACCO, Ralph L. Sugar-sweetened and artificially sweetened beverages in relation to stroke and dementia: are soft drinks hard on the brain? **Stroke**, v. 48, n. 5, p. 1129-1131, maio 2017. DOI: https://doi.org/10.1161/STROKEAHA.117.017198.	**Refrigerante diet e demência** Correlação
WICKHAM, Hadley. Tidy data. **Journal of Statistical Software**, v. 59, n. 10, p. 1-23, 2014. DOI: https://doi.org/10.18637/jss.v059.i10.	**Dado arrumado** Granularidade e integração



Apresentação feita com

applaude

applaude.studio