Limpeza de dados e estatística descritiva

Cinco leituras abertas e gratuitas: duas densas, duas rápidas e uma de aprofundamento.

inteli MBA

#	TIPO	REFERÊNCIA	RESUMO E PROPÓSITO	LINK
1	DENSA ~45 min · inglês	DIEZ, D. M.; ÇETINKAYA-RUNDEL, M.; BARR, C. D. ***OpenIntro Statistics***. 4. ed. [S. l.]: OpenIntro, 2019. **Cap. 2, seções 2.1 e 2.2**	Média, mediana, variância e desvio padrão; quartis, boxplot e histograma; distribuições assimétricas e valores extremos. Na seção 2.2, tabelas para variáveis categóricas. **Propósito:** dar o vocabulário para interpretar o resumo estatístico de cada coluna da base e saber quando a média representa o grupo e quando não representa.	stats.libretexts.org/Bookshelves/Introductory_Statistics/Introduction_to_Statistics_4e_(Diez_et_al.)/02%3A_Summarizing_Data
2	DENSA ~40 min · inglês	McKINNEY, W. ***Python for Data Analysis***: data wrangling with pandas, NumPy, and Jupyter. 3. ed. Sebastopol: O'Reilly, 2022. **Cap. 7, seções 7.1 e 7.2**	Como tratar dados faltantes, remover registros duplicados, padronizar valores e detectar e filtrar outliers. Os exemplos estão em código pandas; o código pode ser lido por cima, o que importa são as decisões de tratamento. **Propósito:** saber o que pedir ao Claude Code ou ao Codex na limpeza da base e conseguir conferir o que ele fez.	wesmckinney.com/book/data-cleaning
3	RÁPIDA ~8 min · português	SHAIBU, S. **Média vs. mediana**: sabendo a diferença. DataCamp, 16 jan. 2026.	Quando usar média e quando usar mediana; como um valor extremo puxa a média e quase não mexe na mediana; o que é uma distribuição assimétrica, com exemplos de renda e preço de imóveis. **Propósito:** reconhecer, numa base real, quando o número médio esconde o comportamento da maioria.	datacamp.com/pt/tutorial/mean-vs-median
4	RÁPIDA ~10 min · português	DUBIELLA, L. **Estatística descritiva**: o que é e quais os tipos de medidas de tendência central. Alura, 21 jan. 2025.	Tipos de variável; média, mediana e moda; amplitude, variância e desvio padrão; leitura de histograma e boxplot, com quartis, intervalo interquartil e outliers. **Propósito:** ler os gráficos e tabelas de resumo que o agente gera durante a análise exploratória.	alura.com.br/artigos/estatistica-descritiva
5	APROFUNDAMENTO ~40 min · inglês	WICKHAM, H. **Tidy data**. *Journal of Statistical Software*, v. 59, n. 10, p. 1–23, 2014.	O que é uma tabela organizada: cada variável em uma coluna, cada observação em uma linha, cada tipo de unidade em uma tabela. Mostra os problemas mais comuns de estrutura e como corrigi-los. **Propósito:** entender a granularidade de cada arquivo da base (cliente, treino, mês) antes de cruzar um com o outro.	jstatsoft.org/article/view/v059i10

Com pouco tempo, leia **3** e **4**. Para a aula render, leia também **1** e **2**.